

Highlights

Accuracy-Preserving Uncertainty Decomposition for Brain Tumor Segmentation with Evidential nnU-Net

Thien B. Nguyen-Tat, Luong Dac Nguyen, Bui Truong Thai Son, Ung Hoang Long

- Tích hợp Evidential Deep Learning vào nnU-Net v2 giúp định lượng độ bất định mà không tốn chi phí lấy mẫu (single forward pass).
- Đề xuất hàm mất mát tổng hợp mới kết hợp Bayes Risk và Dice Loss, khắc phục sự sụt giảm hiệu năng ở các phương pháp EDL trước đây.
- Phân rã thành công độ bất định thành Aleatoric (nhiều ảnh) và Epistemic (dữ liệu lạ), hỗ trợ diễn giải lâm sàng.
- Đạt hiệu năng phân đoạn cao (Dice WT 93.63% trên 5-Fold CV; Mean Dice 88.50% trên Fixed Test) với ECE thấp hơn đáng kể so với Baseline ở mọi cấu hình.

Accuracy-Preserving Uncertainty Decomposition for Brain Tumor Segmentation with Evidential nnU-Net

Thien B. Nguyen-Tat^{a,b}, Luong Dac Nguyen^{a,b}, Bui Truong Thai Son^{a,b} and Ung Hoang Long^{a,b,*}

^aUniversity of Information Technology, Ho Chi Minh City, Vietnam

^bVietnam National University, Ho Chi Minh City, Vietnam

ARTICLE INFO

Keywords:

Brain tumor segmentation
Uncertainty decomposition
nnU-Net
Evidential Deep Learning
BraTS

Tóm tắt nội dung

Phân đoạn khối u não từ ảnh cộng hưởng từ (MRI) bằng học sâu đã đạt được hiệu năng cao với các kiến trúc chuẩn hóa như nnU-Net, tuy nhiên độ tin cậy của dự đoán vẫn là một thách thức lớn. Nhiều phương pháp ước lượng bất định hiện nay thường dẫn đến sự suy giảm hiệu năng phân đoạn, tạo ra sự đánh đổi giữa độ chính xác và khả năng ước lượng bất định.

Trong nghiên cứu này, chúng tôi đề xuất một khung Evidential Deep Learning tích hợp với nnU-Net v2, trong đó một hàm mất mát tổng hợp mới được thiết kế nhằm tối ưu đồng thời quá trình phân đoạn và học bằng chứng. Phương pháp đề xuất giúp duy trì và cải thiện chỉ số Dice ngay cả khi tích hợp cơ chế ước lượng bất định, đồng thời cho phép phân rã bất định dự đoán thành hai thành phần aleatoric và epistemic chỉ trong một lần truyền xuôi (single forward pass).

Các thực nghiệm toàn diện trên bộ dữ liệu BraTS 2020 với hai giao thức đánh giá (5-Fold Cross Validation trên 369 ca và Fixed Split Test trên 74 ca), bao gồm các kịch bản nhiễu và ngoài phân phối, cho thấy phương pháp đề xuất đạt hiệu năng phân đoạn cạnh tranh (Mean Dice 88.96% trên 5-Fold CV), đồng thời vượt trội về độ hiệu chuẩn (ECE 0.805%) và chất lượng bản đồ bất định (BraTS Score 0.930) so với các phương pháp single-pass hiện có.

1. Giới thiệu

Phân đoạn khối u não (Brain Tumor Segmentation) là một thành phần quan trọng trong chẩn đoán và lập kế hoạch điều trị các bệnh lý thần kinh. Việc xác định chính xác vị trí và hình thái của khối u giúp hỗ trợ bác sĩ trong việc lựa chọn phương pháp điều trị phù hợp, từ đó cải thiện tiên lượng cho bệnh nhân. Ảnh cộng hưởng từ đa phương thức (multimodal MRI), bao gồm các chuỗi xung T1, T1ce, T2 và FLAIR, cung cấp thông tin toàn diện về cấu trúc giải phẫu và đặc điểm bệnh học của khối u. Trong những năm gần đây, các phương pháp dựa trên học sâu, đặc biệt là các mạng nơ-ron tích chập như U-Net và biến thể tự cấu hình nnU-Net, đã trở thành chuẩn phổ biến cho bài toán này và được báo cáo là đạt hiệu năng phân đoạn cạnh tranh hàng đầu (state-of-the-art) trên các bộ dữ liệu chuẩn như BraTS [1, 2, 3].

Mặc dù đạt được độ chính xác ấn tượng, việc triển khai các mô hình phân đoạn này trong thực tế lâm sàng vẫn đối mặt với những thách thức đáng kể liên quan đến độ tin cậy. Phần lớn các mô hình hiện đại hoạt động như những hệ thống “hộp đen”, chỉ cung cấp kết quả phân đoạn cuối cùng mà không kèm theo thông tin về mức độ chắc chắn của dự đoán. Một vấn đề nghiêm trọng là hiện tượng tự tin thái quá (overconfidence), trong đó các lớp kích hoạt Softmax có xu hướng tạo ra

các dự đoán với xác suất cao ngay cả khi mô hình đưa ra kết quả sai hoặc khi gặp dữ liệu bị nhiễu hay ngoài phân phối (out-of-distribution – OOD) [4]. Trong bối cảnh y tế, những dự đoán sai nhưng có độ tin cậy cao như vậy có thể dẫn đến các quyết định lâm sàng rủi ro.

Nguyên nhân cốt lõi của vấn đề này nằm ở bản chất của Softmax, vốn chỉ cung cấp một ước lượng điểm (point estimate) cho phân phối nhãn và không thể biểu diễn hay phân biệt các nguồn bất định khác nhau. Trong thực tế, bất định trong phân đoạn y sinh thường bao gồm hai thành phần chính: bất định aleatoric, phát sinh từ nhiễu nội tại của dữ liệu hoặc ranh giới mờ của khối u, và bất định epistemic, phản ánh sự thiếu hiểu biết của mô hình đối với các mẫu hiếm hoặc chưa từng quan sát trong quá trình huấn luyện [5]. Việc không phân biệt được hai loại bất định này khiến các mô hình phân đoạn khó có khả năng tự đánh giá mức độ tin cậy của chính mình.

Để giải quyết những hạn chế trên, Evidential Deep Learning (EDL) đã được đề xuất như một hướng tiếp cận thay thế, trong đó đầu ra của mạng được diễn giải như các bằng chứng và được tham số hóa bằng phân phối Dirichlet dựa trên lý thuyết bằng chứng Dempster-Shafer [6]. Cách tiếp cận này cho phép ước lượng bất định trực tiếp trong một lần suy luận (single-pass inference), tránh chi phí tính toán lớn của các phương pháp Bayesian dựa trên lấy mẫu như MC Dropout hay ensemble [7]. Tuy nhiên, các nghiên cứu gần đây cho thấy việc tích hợp EDL vào các mô hình phân đoạn thường dẫn đến sự suy giảm hiệu năng phân

*Corresponding author. Giảng viên hướng dẫn

✉ thienntb@uit.edu.vn (T.B. Nguyen-Tat)

orcid(s):

đoạn, đặc biệt là chỉ số Dice, làm nổi bật sự đánh đổi giữa độ chính xác và khả năng ước lượng bất định [8, 9].

Trong nghiên cứu này, chúng tôi đề xuất một khung Evidential Deep Learning tích hợp với kiến trúc nnU-Net v2 nhằm giải quyết trực tiếp sự đánh đổi này. Bằng cách thiết kế một hàm mất mát tổng hợp mới và áp dụng cơ chế phân rã bất định thành các thành phần aleatoric và epistemic, phương pháp của chúng tôi hướng tới việc duy trì và cải thiện hiệu năng phân đoạn đồng thời cung cấp thông tin bất định có khả năng diễn giải, góp phần nâng cao độ tin cậy của các hệ thống phân đoạn khối u não trong thực tế lâm sàng.

2. Các nghiên cứu liên quan

2.1. Học sâu trong phân đoạn khối u não

Trong hơn một thập kỷ qua, các mạng nơ-ron tích chập (CNN) đã tạo ra những bước tiến đáng kể trong phân tích ảnh y tế, đặc biệt là bài toán phân đoạn khối u não từ ảnh cộng hưởng từ. Kiến trúc U-Net, với cơ chế kết nối tắt (skip connections) giữa các tầng mã hóa và giải mã, đã trở thành nền tảng cho hầu hết các mô hình phân đoạn y sinh hiện đại nhờ khả năng kết hợp hiệu quả thông tin ngữ cảnh và chi tiết không gian [1]. Dựa trên U-Net, nhiều biến thể và cải tiến đã được đề xuất nhằm xử lý dữ liệu đa phương thức và cấu trúc khối u phức tạp.

Gần đây, nnU-Net được giới thiệu như một khung phân đoạn tự cấu hình, có khả năng tự động điều chỉnh kiến trúc mạng, chiến lược tiền xử lý và siêu tham số huấn luyện theo đặc điểm của từng bộ dữ liệu [2]. Nhờ cách tiếp cận chuẩn hóa toàn bộ pipeline, nnU-Net đã đạt được hiệu năng phân đoạn hàng đầu trên các bộ dữ liệu benchmark như BraTS và được xem là chuẩn tham chiếu trong cộng đồng nghiên cứu [3]. Tuy nhiên, các mô hình dựa trên nnU-Net về bản chất vẫn là các mô hình tất định (deterministic), không cung cấp thông tin về độ tin cậy của dự đoán, điều này hạn chế khả năng ứng dụng trong các kịch bản hỗ trợ quyết định lâm sàng.

2.2. Ước lượng độ bất định: Tiếp cận Bayesian và Evidential

Nhằm khắc phục hạn chế “hộp đen” của các mô hình tất định, nhiều phương pháp ước lượng bất định đã được đề xuất trong học sâu. Các phương pháp Bayesian, tiêu biểu như Monte Carlo Dropout và Deep Ensembles, xấp xỉ phân phối hậu nghiệm của mô hình bằng cách thực hiện nhiều lần suy luận ngẫu nhiên trong giai đoạn dự đoán [7, 10]. Mặc dù cho phép ước lượng bất định ở mức độ nhất định, các phương pháp này thường đòi hỏi chi phí tính toán cao do phải thực hiện nhiều forward passes, gây khó khăn cho các ứng dụng thời gian thực hoặc các bài toán phân đoạn 3D quy mô lớn.

Evidential Deep Learning (EDL) được đề xuất như một hướng tiếp cận thay thế nhằm giảm chi phí suy

luận. Dựa trên lý thuyết bằng chứng Dempster-Shafer, EDL diễn giải đầu ra của mạng dưới dạng các tham số của phân phối Dirichlet, cho phép mô hình biểu diễn mức độ bằng chứng và ước lượng bất định trực tiếp trong một lần suy luận (single-pass inference), trái ngược với các phương pháp tiếp cận dựa trên lấy mẫu [6]. Cách tiếp cận này đã cho thấy tiềm năng trong các bài toán phân loại, tuy nhiên việc mở rộng EDL sang các bài toán phân đoạn phức tạp, đặc biệt là phân đoạn khối u não, vẫn đặt ra nhiều thách thức về tính ổn định và hiệu năng.


2.3. Evidential Deep Learning cho phân đoạn khối u não

Một số nghiên cứu gần đây đã nỗ lực tích hợp EDL vào bài toán phân đoạn khối u não. TBraTS là một trong những công trình tiên phong áp dụng EDL cho phân đoạn khối u não, sử dụng kiến trúc V-Net làm backbone và định lượng bất định thông qua thước đo vacuity dựa trên Subjective Logic [8]. Tuy nhiên, ngoài việc chưa tận dụng các kiến trúc phân đoạn chuẩn hóa, TBraTS còn tồn tại một hạn chế mang tính cấu trúc trong cách thiết kế hàm mất mát. Cụ thể, để đối phó với bài toán mất cân bằng lớp nghiêm trọng trong phân đoạn khối u, TBraTS kết hợp hàm Evidential Cross-Entropy loss (tính trên tham số Dirichlet α thông qua hàm digamma) với Soft Dice Loss. Tuy nhiên, thành phần Dice Loss được tính bằng cách đưa trực tiếp đầu ra bằng chứng qua một lớp Softmax bổ sung (Softmax(α)) thay vì sử dụng xác suất kỳ vọng từ phân phối Dirichlet ($\hat{p}_k = \alpha_k / S$). Cách cài đặt này tạo ra hai đường tối ưu hóa song song và mâu thuẫn: nhánh EDL loss buộc mạng học bằng chứng theo khuôn khổ Dirichlet, trong khi nhánh Softmax-Dice loss bỏ qua ngữ nghĩa bằng chứng và chỉ tối ưu hình dạng phân đoạn theo phân phối xác suất được chuẩn hóa lại. Hệ quả là các giá trị bằng chứng đầu ra có thể không phản ánh đúng mức độ tự tin theo lý thuyết EDL, làm giảm tính tin cậy của các ước lượng bất định [9].

Gần đây hơn, phương pháp Region-based Evidential Deep Learning đã được đề xuất nhằm cải thiện EDL cho phân đoạn bằng cách kết hợp các hàm mất mát dựa trên vùng với cơ chế regularization của Dirichlet, sử dụng nnU-Net làm backbone [9]. Mặc dù phương pháp này cho thấy những cải thiện nhất định so với các cách tiếp cận EDL trước đó, một số nghiên cứu gần đây đã quan sát thấy rằng việc tích hợp EDL vào các mô hình phân đoạn có thể dẫn đến sự suy giảm hiệu năng phân đoạn so với các mô hình thuần túy, phản ánh sự đánh đổi giữa độ chính xác và khả năng ước lượng bất định.

2.4. Phân rã độ bất định và khả năng diễn giải

Trong bối cảnh ứng dụng lâm sàng, không chỉ mức độ bất định tổng thể mà cả nguồn gốc của bất định đều mang ý nghĩa quan trọng. Trong học sâu, bất định thường được phân loại thành hai thành phần chính:



Hình 1: Sơ đồ tổng quan kiến trúc EDL-nnU-Net đề xuất. Mô hình nhận đầu vào là ảnh MRI đa phương thức (BraTS) và sử dụng kiến trúc Encoder-Decoder (nnU-Net) để trích xuất đặc trưng. Đầu ra không sử dụng Softmax truyền thống mà được mô hình hóa dưới dạng phân phối Dirichlet, cho phép ước lượng đồng thời bản đồ phân đoạn và các thành phần độ bất định (aleatoric và epistemic) trong một lần truyền xuôi.

bất định aleatoric, phản ánh nhiễu nội tại của dữ liệu quan sát, và bất định epistemic, liên quan đến sự thiếu hiểu biết của mô hình đối với các mẫu hiếm hoặc ngoài phân phối [5]. Việc phân rã bất định thành các thành phần này giúp cải thiện khả năng diễn giải và hỗ trợ các quyết định lâm sàng an toàn hơn.

Mặc dù khái niệm phân rã bất định đã được nghiên cứu trong các bài toán phân loại và thị giác máy tính tổng quát, phần lớn các phương pháp phân đoạn y sinh hiện nay chỉ cung cấp một bản đồ bất định tổng hợp, thường được suy ra từ entropy hoặc phương sai của dự đoán [11]. Ngay cả trong các phương pháp EDL cho phân đoạn, trọng tâm chủ yếu vẫn đặt vào việc ước lượng bất định tổng thể, trong khi việc phân rã rõ ràng các thành phần aleatoric và epistemic trong không gian phân đoạn vẫn chưa được nghiên cứu một cách hệ thống.

Do đó, vẫn còn thiếu các phương pháp phân đoạn khối u não có khả năng vừa duy trì hiệu năng phân đoạn cao, vừa cung cấp bản đồ bất định có thể phân rã và diễn giải rõ ràng, đặc biệt khi sử dụng các backbone chuẩn hóa như nnU-Net. Khoảng trống này chính là động lực cho phương pháp được đề xuất trong nghiên cứu này.

3. Phương pháp đề xuất

3.1. Tổng quan về framework đề xuất

Chúng tôi đề xuất một khung phân đoạn khối u não dựa trên Evidential Deep Learning, được tích hợp trực

tiếp vào kiến trúc nnU-Net v2 thông qua một cơ chế huấn luyện tùy biến, nhằm đồng thời đạt được hiệu năng phân đoạn cao và khả năng định lượng bất định có khả năng diễn giải.

Khác với các phương pháp mở rộng nnU-Net bằng cách thay đổi kiến trúc hoặc pipeline tiền xử lý, phương pháp của chúng tôi giữ nguyên toàn bộ cơ chế tự cấu hình của nnU-Net, bao gồm chiến lược tiền xử lý, lập kế hoạch kiến trúc, deep supervision và chiến lược huấn luyện mặc định. Phần mở rộng được thực hiện bằng cách tiêm (inject) một trainer tùy biến vào khung huấn luyện của nnU-Net v2, cho phép thay thế lớp đầu ra và hàm mất mát mà không làm gián đoạn các thành phần đã được tối ưu hóa sẵn của hệ thống.

Tổng thể, khung phương pháp bao gồm ba thành phần chính. Thứ nhất, nnU-Net v2 đóng vai trò backbone phân đoạn 3D, xử lý dữ liệu MRI đa phương thức và tạo ra các bản đồ logits cho từng voxel. Thứ hai, các logits này được ánh xạ sang bằng chứng không âm thông qua hàm kích hoạt Softplus, từ đó tham số hóa một phân phối Dirichlet cho mỗi voxel và mỗi lớp phân đoạn. Thứ ba, một hàm mất mát tổng hợp mới được thiết kế nhằm cân bằng giữa tối ưu hóa Dice score và việc học bằng chứng một cách có kiểm soát, tránh hiện tượng suy giảm hiệu năng thường gặp trong các phương pháp EDL trước đó.

Ở giai đoạn suy luận, framework cho phép tính toán phân phối dự đoán kỳ vọng và các bản đồ bất định chỉ trong một lần truyền xuôi (single-pass inference), đồng

thời hỗ trợ phân rã bất định thành các thành phần aleatoric và epistemic. Điều này giúp phương pháp phù hợp với các kịch bản lâm sàng thực tế, nơi yêu cầu cả độ chính xác, độ tin cậy và hiệu quả tính toán.

3.2. Mô hình hóa Evidential với phân phối

Dirichlet

Trong các mô hình phân đoạn truyền thống, đầu ra của mạng thường được chuẩn hóa bằng hàm Softmax để tạo ra một phân phối xác suất điểm trên các lớp. Cách tiếp cận này không cho phép mô hình biểu diễn mức độ thiếu chắc chắn của chính dự đoán, đồng thời dễ dẫn đến hiện tượng tự tin thái quá khi đối mặt với dữ liệu nhiễu hoặc ngoài phân phối.

Trong khuôn khổ Evidential Deep Learning, chúng tôi diễn giải đầu ra của mạng như các bằng chứng thay vì xác suất trực tiếp, từ đó tham số hóa một phân phối Dirichlet [6]. Cụ thể, với mỗi voxel i và mỗi lớp phân đoạn $k \in \{1, \dots, K\}$, mạng dự đoán một logit z_{ik} . Logit này được chuyển đổi thành bằng chứng không âm thông qua hàm kích hoạt Softplus:

$$e_{ik} = \text{Softplus}(z_{ik}) = \ln(1 + \exp(z_{ik})) \quad (1)$$

Đây là một hàm kích hoạt trơn và không âm (smooth non-negative activation), giúp đảm bảo tính hợp lệ của bằng chứng đồng thời duy trì gradient mượt ngay cả với các logit âm, khắc phục hạn chế của ReLU trong bối cảnh học bằng chứng.

Các bằng chứng này được dùng để tham số hóa phân phối Dirichlet:

$$\alpha_{ik} = e_{ik} + 1 \quad (2)$$

trong đó $\alpha_i = \{\alpha_{i1}, \dots, \alpha_{iK}\}$ xác định một phân phối Dirichlet trên simplex xác suất cho voxel i . Khi không có bằng chứng ($e_{ik} = 0$), ta có $\alpha_{ik} = 1$, tương ứng với phân phối đồng đều và mức bất định tối đa.

Xác suất dự đoán kỳ vọng cho mỗi lớp được tính trực tiếp từ phân phối Dirichlet:

$$\hat{p}_{ik} = \mathbb{E}[p_{ik}] = \frac{\alpha_{ik}}{S_i}, \quad S_i = \sum_{k=1}^K \alpha_{ik} \quad (3)$$

Khác với xác suất Softmax, $\hat{p}_{ik}$ không chỉ phản ánh xu hướng phân lớp mà còn phụ thuộc vào tổng cường độ bằng chứng S_i . Khi S_i nhỏ, phân phối Dirichlet trở nên phẳng, phản ánh sự thiếu chắc chắn của mô hình; khi S_i lớn, phân phối trở nên tập trung hơn, biểu thị mức độ tự tin cao.

Trong nghiên cứu này, các xác suất kỳ vọng $\hat{p}_{ik}$ được sử dụng trực tiếp để tối ưu hóa hàm Dice loss, trong khi các tham số Dirichlet được khai thác để học và phân tích bất định. Cách thiết kế này cho phép mô hình duy trì hành vi phân đoạn tương tự nnU-Net chuẩn, đồng thời mở rộng đầu ra để hỗ trợ định lượng và phân rã bất định một cách có hệ thống.

3.3. Hàm mất mát tổng hợp bảo toàn độ chính xác (Accuracy-Preserving Composite Loss)

Một thách thức cốt lõi khi áp dụng Evidential Deep Learning cho bài toán phân đoạn là sự đánh đổi giữa hiệu năng phân đoạn và khả năng ước lượng bất định. Các hàm mất mát EDL truyền thống thường ưu tiên tối ưu hóa bằng chứng (evidence) nhưng thiếu sự tập trung vào độ chồng lấp hình học (geometric overlap), dẫn đến hiện tượng hội tụ chậm và chỉ số Dice thấp hơn so với các phương pháp phân đoạn nền tảng mạnh mẽ (strong segmentation baselines).

Để giải quyết vấn đề này, chúng tôi đề xuất một hàm mất mát tổng hợp mới. Hàm mất mát này tích hợp Soft Dice Loss để duy trì hiệu năng phân đoạn của nnU-Net [12], đồng thời sử dụng Bayes Risk để học bằng chứng một cách hiệu quả [6]. Tổng hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{seg}} + \mathcal{L}_{\text{risk}} + \lambda_t \mathcal{L}_{\text{KL}} \quad (4)$$

trong đó λ_t là hệ số trọng số thay đổi theo thời gian (annealing coefficient) để kiểm soát thành phần regularization.

3.3.1. Hàm mất mát phân đoạn trên phân phối dự đoán kỳ vọng

Thành phần $\mathcal{L}_{\text{seg}}$ đóng vai trò chủ đạo trong việc đảm bảo độ chính xác phân đoạn. Thay vì tính loss trên logits, chúng tôi tính Soft Dice Loss trực tiếp trên phân phối dự đoán kỳ vọng của Dirichlet $\hat{p}_{ik} = \alpha_{ik}/S_i$:

$$\mathcal{L}_{\text{seg}} = 1 - \frac{2 \sum_i \sum_k \hat{p}_{ik} y_{ik}}{\sum_i \sum_k (\hat{p}_{ik} + y_{ik})} \quad (5)$$

Cách tiếp cận này giúp gradient từ sai số phân đoạn được lan truyền ngược trực tiếp để điều chỉnh các tham số Dirichlet α_{ik} , đảm bảo rằng mô hình không chỉ học được phân phối xác suất mà còn tối ưu hóa được hình dạng vùng tổn thương [12].

Đối chiếu với cách tiếp cận của TBraTS. Điểm khác biệt then chốt nằm ở cách tính Dice Loss. TBraTS [8] đưa đầu ra bằng chứng α qua một lớp Softmax bổ sung để thu được xác suất tính Dice, tức $\tilde{p}_{ik} = \text{Softmax}(\alpha)_k$. Cách cài đặt này phá vỡ tính nhất quán của khung EDL: hàm Softmax chuẩn hóa lại các tham số Dirichlet theo một phép biến đổi phi tuyến không bảo toàn ngữ nghĩa bằng chứng, tạo ra hai mục tiêu tối ưu mâu thuẫn — nhánh EDL loss kéo α_k theo hướng phản ánh cường độ bằng chứng, trong khi nhánh Softmax-Dice loss chỉ quan tâm đến tỷ lệ tương đối $e^{\alpha_k}/\sum_j e^{\alpha_j}$ mà không phụ thuộc vào biên độ tuyệt đối. Hệ quả là các giá trị evidence đầu ra có thể không mang ý nghĩa xác suất đúng theo lý thuyết Dirichlet.

Ngược lại, phương pháp đề xuất tính Dice Loss trực tiếp trên kỳ vọng Dirichlet $\hat{p}_{ik} = \alpha_{ik}/S_i$, trong đó $S_i = \sum_k \alpha_{ik}$. Phép chia tuyến tính này bảo toàn hoàn toàn mối liên hệ giữa cường độ bằng chứng và xác suất dự đoán: mọi gradient từ Dice Loss đều truyền ngược

qua α_{ik} theo đúng ngữ nghĩa Dirichlet, đảm bảo các thành phần loss hoạt động đồng thuận trên cùng một không gian tham số.

3.3.2. Rủi ro Bayes (Bayes risk) cho việc học bằng chứng

Để mô hình học được bằng chứng từ dữ liệu, chúng tôi sử dụng Bayes Risk loss, được định nghĩa là kỳ vọng của Cross-Entropy loss trên phân phối Dirichlet [6]:

$$\mathcal{L}_{\text{risk}} = \sum_i \sum_k y_{ik} (\psi(S_i) - \psi(\alpha_{ik})) \quad (6)$$

trong đó $\psi(\cdot)$ là hàm digamma. Thành phần này phạt mô hình nếu nó gán ít bằng chứng cho lớp đúng (ground truth) và nhiều bằng chứng cho các lớp sai.

3.3.3. Điều chuẩn KL divergence với chiến lược Annealing

Để ngăn chặn hiện tượng tự tin thái quá, chúng tôi áp dụng KL divergence để ép phân phối dự đoán về dạng phân phối Dirichlet đồng đều (Uniform Dirichlet) đối với các mẫu khó hoặc gây nhầm lẫn:

$$\mathcal{L}_{\text{KL}} = \text{KL}[\text{Dir}(\alpha_i) \parallel \text{Dir}(\mathbf{1})] \quad (7)$$

Đặc biệt, để tránh việc regularization quá mạnh làm cản trở quá trình học đặc trưng ở giai đoạn đầu, chúng tôi áp dụng cơ chế Annealing cho hệ số λ_t [6]. Cụ thể, λ_t được tăng tuyến tính từ 0 đến 1 trong các epoch huấn luyện đầu tiên (early training epochs). Điều này cho phép mô hình ưu tiên học phân đoạn chính xác trước khi dần dần học cách hiệu chỉnh độ bất định.

3.4. Phân rã độ bất định (Uncertainty

Decomposition)

Một ưu điểm cốt lõi của phương pháp đề xuất là khả năng phân rã bất định tổng thể thành hai thành phần có ý nghĩa lâm sàng riêng biệt: bất định aleatoric (do nhiễu dữ liệu) và epistemic (do thiếu tri thức của mô hình). Phần này trình bày cơ sở lý thuyết thông tin cho phép phân rã và dẫn xuất các công thức dạng đóng trong khuôn khổ Dirichlet [5, 13].

3.4.1. Cơ sở lý thuyết thông tin

Xét bài toán dự đoán nhãn y cho một voxel, với phân phối xác suất $\mathbf{p}$ trên K lớp được mô hình hóa bởi phân phối Dirichlet $\mathbf{p} \sim \text{Dir}(\alpha)$. Từ lý thuyết thông tin, thông tin tương hỗ (Mutual Information) giữa nhãn dự đoán y và phân phối xác suất $\mathbf{p}$ cho phép phân tách entropy tổng thể một cách chính xác:

$$\underbrace{I[y; \mathbf{p}]}_{\text{Epistemic}} = \underbrace{H[\mathbb{E}[\mathbf{p}]]}_{\text{Total Uncertainty}} - \underbrace{\mathbb{E}[H[\mathbf{p}]]}_{\text{Aleatoric Uncertainty}} \quad (8)$$

Đẳng thức (8) là một hệ quả trực tiếp của luật phân rã entropy có điều kiện: $H[y] = H[y|\mathbf{p}] + I[y; \mathbf{p}]$. Về trái là entropy biên (marginal entropy) của dự đoán, về phải

tách thành phần ngẫu nhiên nội tại ($H[y|\mathbf{p}]$, trung bình trên phân phối Dirichlet) và phần do sự thiếu chắc chắn của mô hình ($I[y; \mathbf{p}]$). Đẳng thức này luôn đúng, không cần xấp xỉ, miễn là phân phối posterior trên $\mathbf{p}$ được xác định.

Hình 2 minh họa trực quan ba trạng thái đặc trưng trên không gian đơn hình (Simplex) xác suất.

3.4.2. Dẫn xuất các công thức dạng đóng cho phân phối Dirichlet

Trong khuôn khổ EDL, phân phối posterior trên $\mathbf{p}$ là phân phối Dirichlet $\text{Dir}(\alpha)$ với $S = \sum_k \alpha_k$. Chúng tôi dẫn xuất lần lượt từng thành phần của đẳng thức (8).

(a) Độ bất định tổng thể (Total predictive uncertainty). Thành phần này là entropy Shannon của phân phối dự đoán kỳ vọng $\hat{\mathbf{p}} = \mathbb{E}[\mathbf{p}]$:

$$\mathcal{H}_{\text{total}} = H[\hat{\mathbf{p}}] = - \sum_{k=1}^K \frac{\alpha_k}{S} \ln \frac{\alpha_k}{S} \quad (9)$$

Đây là đại lượng đo sự hỗn loạn của quyết định phân đoạn cuối cùng.

(b) Độ bất định ngẫu nhiên (Aleatoric uncertainty). Thành phần này là kỳ vọng của entropy trên phân phối Dirichlet:

$$\mathcal{U}_{\text{aleatoric}} = \mathbb{E}_{\text{Dir}(\alpha)}[H[\mathbf{p}]] = - \sum_{k=1}^K \mathbb{E}[p_k \ln p_k] \quad (10)$$

Để tính $\mathbb{E}[p_k \ln p_k]$, chúng tôi sử dụng tính chất dịch chuyển (shift property) của phân phối Dirichlet. Với $\mathbf{p} \sim \text{Dir}(\alpha)$ và một hàm g bất kỳ, ta có:

$$\mathbb{E}[p_k \cdot g(p_k)] = \frac{\alpha_k}{S} \mathbb{E}_{\text{Dir}(\alpha^{(k)})}[g(p_k)] \quad (11)$$


trong đó $\alpha^{(k)}$ là bộ tham số Dirichlet với $\alpha_k^{(k)} = \alpha_k + 1$ và $\alpha_j^{(k)} = \alpha_j$ ($j \neq k$), có tổng $S^{(k)} = S + 1$. Áp dụng (11) cho $g(p_k) = \ln p_k$ và sử dụng kết quả chuẩn $\mathbb{E}_{\text{Dir}(\beta)}[\ln p_k] = \psi(\beta_k) - \psi(\sum_j \beta_j)$ [13], ta được:

$$\mathbb{E}[p_k \ln p_k] = \frac{\alpha_k}{S} [\psi(\alpha_k + 1) - \psi(S + 1)] \quad (12)$$

Do đó, biểu thức dạng đóng của Aleatoric Uncertainty là:

$$\mathcal{U}_{\text{aleatoric}} = \sum_{k=1}^K \frac{\alpha_k}{S} [\psi(S + 1) - \psi(\alpha_k + 1)] \quad (13)$$

Giá trị này đạt cực đại khi các α_k gần bằng nhau (bằng chứng phân bố đều giữa các lớp, phản ánh ranh giới mơ hồ hoặc nhiễu dữ liệu), và tiến về 0 khi một α_k chiếm ưu thế (dự đoán rõ ràng). Quan sát Hình 2 (giữa) giúp hình dung: khi mô hình “lưỡng lự” giữa các lớp, phân phối xác suất dồn về trọng tâm đơn hình, dẫn đến Entropy kỳ vọng tăng cao.



Hình 2: Minh họa phân phối Dirichlet trên Simplex cho bài toán 3 lớp. **(Trái)** Dự đoán tự tin (S lớn): phân phối tập trung tại đỉnh, cả Total lẫn Aleatoric đều thấp. **(Giữa)** High Aleatoric: dữ liệu nhiễu (biên mờ) khiến bằng chứng mâu thuẫn, phân phối co cụm vào trung tâm (Entropy cực đại) nhưng vẫn tập trung $\Rightarrow$ Epistemic thấp. **(Phải)** High Epistemic: dữ liệu lạ (OOD) thiếu bằng chứng ($\alpha_k \rightarrow 1$), phân phối trải phẳng đều $\Rightarrow$ phương sai giữa các lần lấy mẫu lớn.

(c) Độ bất định nhận thức (Epistemic uncertainty). Từ đẳng thức phân rã (8), Epistemic Uncertainty được xác định:

$$\mathcal{U}_{\text{epistemic}} = \mathcal{H}_{\text{total}} - \mathcal{U}_{\text{aleatoric}} = \sum_{k=1}^K \frac{\alpha_k}{S} \left[\psi(\alpha_k + 1) - \psi(S + 1) - \ln \frac{\alpha_k}{S} \right] \quad (14)$$

Đại lượng này đo sự phân kỳ giữa entropy của dự đoán kỳ vọng và entropy kỳ vọng của dự đoán, hay nói cách khác, đo độ phân tán của phân phối posterior trên không gian xác suất.

Để hiểu hành vi tiệm cận, ta sử dụng khai triển $\psi(x+1) = \ln(x) + \frac{1}{2x} + O(x^{-2})$. Khi tổng bằng chứng S lớn (mô hình tự tin), $\psi(\alpha_k + 1) - \psi(S + 1) \approx \ln(\alpha_k/S) = \ln(\hat{p}_k)$, khiến từng số hạng trong (14) tiến về 0 – phù hợp trực giác rằng mô hình được huấn luyện tốt sẽ có Epistemic thấp. Ngược lại, khi thiếu bằng chứng ($\alpha_k \rightarrow 1$, $S \rightarrow K$), phân phối Dirichlet trải phẳng (Hình 2, phải), giá trị digamma lệch xa logarit, và Epistemic đạt giá trị cao – phản ánh sự thiếu hiểu biết của mô hình đối với dữ liệu ngoài phân phối.

3.4.3. Ý nghĩa lâm sàng

Phân rã (8) mang lại hai tín hiệu hành động riêng biệt cho bác sĩ:

- Aleatoric cao $\Rightarrow$ ranh giới khối u mờ hoặc chất lượng ảnh kém. Hành động: yêu cầu chụp lại hoặc tham vấn thêm.
- Epistemic cao $\Rightarrow$ mô hình chưa gặp dạng bệnh lý này. Hành động: chuyển ca bệnh cho chuyên gia hoặc thu thập thêm dữ liệu huấn luyện.

4. Thiết lập thực nghiệm

4.1. Dữ liệu và chi tiết cài đặt

4.1.1. Dữ liệu và Tiền xử lý

Chúng tôi đánh giá phương pháp đề xuất trên bộ dữ liệu chuẩn BraTS 2020 [3], bao gồm các ảnh cộng hưởng từ đa phương thức (T1, T1ce, T2 và FLAIR) của 369 bệnh nhân được chẩn đoán u thần kinh đệm

(glioma). Mỗi mẫu dữ liệu được gán nhãn voxel-wise bởi các chuyên gia, với ba lớp chính: hoại tử và không tăng quang (NCR/NET – nhãn 1), phù nề (ED – nhãn 2), và lõi tăng quang (ET – nhãn 4).

Hiệu năng phân đoạn được đánh giá trên ba vùng lâm sàng chồng lấp (nested regions), bao gồm: Whole Tumor (WT), đại diện cho toàn bộ vùng u (nhãn $1 \cup 2 \cup 4$); Tumor Core (TC), bao gồm vùng hoại tử và lõi tăng quang (nhãn $1 \cup 4$); và Enhancing Tumor (ET), chỉ bao gồm lõi tăng quang (nhãn 4). Cách phân chia này tuân theo giao thức đánh giá tiêu chuẩn của các thử thách BraTS.

Toàn bộ dữ liệu được tiền xử lý tự động theo pipeline self-configuring của nnU-Net v2 [2]. Quy trình này bao gồm chuẩn hóa cường độ bằng z-score cho từng phương thức MRI, cắt vùng não (brain cropping), và lấy mẫu lại (resampling) về cùng độ phân giải không gian.

4.1.2. Giao thức đánh giá

Để đảm bảo tính khách quan và minh bạch học thuật, chúng tôi sử dụng song song hai giao thức đánh giá:

1. 5-Fold Cross Validation (369 ca): Đây là giao thức đánh giá tiêu chuẩn và toàn diện nhất, trong đó mỗi bệnh nhân đều lần lượt đóng vai trò dữ liệu kiểm thử. Việc phân chia dữ liệu huấn luyện và kiểm định được thực hiện tự động bởi nnU-Net với seed ngẫu nhiên cố định mặc định (split_seed = 12345), và file cấu hình phân chia (splits_final.json) được tạo theo chiến lược kiểm định chéo 5 lần.
2. Fixed Split Test (74 ca): Chúng tôi sử dụng tập Validation của Fold 0 theo cách chia 5-Fold Cross Validation trên (khoảng 20% dữ liệu, gồm 74 bệnh nhân) làm tập kiểm thử độc lập, phần dữ liệu còn lại gồm 236 ca dùng để huấn luyện (training) và 59 ca dùng để kiểm định (validation). Giao thức này nhằm đối chiếu công bằng với các phương pháp SOTA khác thường tự chia tập test với quy mô tương đương.

4.1.3. Cấu hình mạng và Huấn luyện

Các thực nghiệm được triển khai trên nền tảng PyTorch, sử dụng framework nnU-Net v2. Chúng tôi so sánh hai cấu hình mô hình:

1. Baseline: Mô hình nnU-Net chuẩn (cấu hình 3d_fullres), sử dụng hàm kích hoạt Softmax và hàm mất mát kết hợp Dice và Cross-Entropy.
2. EDL-nnU-Net (đề xuất): Mô hình đề xuất, trong đó lớp đầu ra được thay thế bằng hàm kích hoạt Softplus và hàm mất mát tổng hợp như mô tả ở Mục 3.

Cả hai mô hình được huấn luyện trên cùng phần cứng (GPU NVIDIA RTX PRO 6000, 96GB VRAM) nhằm đảm bảo điều kiện so sánh công bằng. Theo thiết lập mặc định của nnU-Net, bộ tối ưu hóa SGD với momentum 0.99 và weight decay 3×10^{-5} được sử dụng, với tốc độ học ban đầu 0.01 theo chính sách poly learning rate scheduler.

Để đánh giá ảnh hưởng của thời gian huấn luyện đến cả hiệu năng phân đoạn lẫn độ hiệu chuẩn, chúng tôi thiết lập hai mốc huấn luyện: 50 epochs và 250 epochs. Đối với mô hình EDL-nnU-Net, hệ số annealing λ_t của thành phần KL divergence được tăng tuyến tính từ 0 đến 1 trong 100 epochs đầu tiên, cho phép mô hình ưu tiên học phân đoạn chính xác ở giai đoạn đầu trước khi dần dần hiệu chỉnh độ bất định.

4.2. Các phương pháp đối chứng

Để đánh giá vị thế của phương pháp đề xuất, chúng tôi so sánh với ba phương pháp đối chứng đại diện cho các hướng tiếp cận khác nhau:

- Standard nnU-Net (Deterministic baseline) [2]: Chuẩn tham chiếu cho phân đoạn y sinh, đóng vai trò mốc so sánh quan trọng để đánh giá liệu việc tích hợp EDL có thể duy trì hiệu năng phân đoạn của một mô hình tất định mạnh hay không.
- TBraTS (Trusted Brain Tumor Segmentation) [8]: Công trình tiên phong tích hợp EDL vào phân đoạn khối u não, sử dụng kiến trúc V-Net làm backbone và định lượng bất định qua thước đo vacuity dựa trên Subjective Logic.
- Region-based EDL [9]: Phương pháp gần nhất với nghiên cứu này do cùng sử dụng nnU-Net làm backbone, kết hợp EDL với regularization Dirichlet. Việc so sánh cho phép đánh giá trực tiếp hiệu quả của hàm mất mát Composite Loss đề xuất.

4.3. Các chỉ số đánh giá (Evaluation Metrics)

Để đánh giá toàn diện, chúng tôi xem xét cả độ chính xác phân đoạn và độ tin cậy của các ước lượng bất định.

4.3.1. Hiệu suất phân đoạn

Chất lượng phân đoạn được định lượng bằng Hệ số tương đồng Dice (DSC) và Khoảng cách Hausdorff 95% (HD95).

Hệ số Dice đo lường mức độ chồng lấn về thể tích giữa bản đồ phân đoạn dự đoán P và nhãn thực tế G :

$$DSC(P, G) = \frac{2|P \cap G|}{|P| + |G|} \quad (15)$$

Giá trị DSC nằm trong khoảng $[0, 1]$, càng gần 1 càng tốt. HD95 đánh giá độ chính xác đường biên bằng phân vị thứ 95 của khoảng cách giữa bề mặt dự đoán và thực tế, với giá trị càng nhỏ càng tốt.

4.3.2. Đánh giá hiệu chuẩn

Mức độ hiệu chuẩn của mô hình được đo bằng Expected Calibration Error (ECE), đánh giá sự chênh lệch giữa độ tự tin và độ chính xác thực tế, với giá trị càng thấp càng tốt.

4.3.3. Đánh giá độ tin cậy (Giao thức QU-BraTS)

Ngoài các chỉ số tiêu chuẩn, chúng tôi đánh giá mức độ đáng tin cậy dựa trên giao thức từ cuộc thi QU-BraTS 2020 Challenge [14]. Giao thức này đánh giá hành vi của mô hình khi các voxel có độ bất định cao bị loại bỏ dần theo ngưỡng τ , dựa trên ba đường cong chính:

1. Dice-Retention Curve: Sự cải thiện của DSC khi loại bỏ voxel không chắc chắn.
2. False Trust Positive (FTP): Tỷ lệ voxel nền bị phân loại sai với độ tin cậy cao.
3. False Trust Negative (FTN): Tỷ lệ voxel khối u bị bỏ sót với độ tin cậy cao.

Điểm số QU-BraTS (BraTS Score) được tính:

$$\text{Score}_{QU} = \frac{AUC_{Dice} + (1 - AUC_{FTP}) + (1 - AUC_{FTN})}{3} \quad (16)$$

Điểm số cao cho thấy mô hình không chỉ chính xác mà còn giảm độ bất định cao cho những vùng dự đoán sai.

Phân tích tính bền vững (Robustness Analysis) Bên cạnh các đánh giá tiêu chuẩn, chúng tôi còn thực hiện các thí nghiệm về tính bền vững dưới tác động của nhiễu tổng hợp (synthetic noise perturbations) nhằm phân tích hành vi của các ước lượng bất định khi chất lượng hình ảnh bị suy giảm. Chi tiết sẽ được trình bày trong Mục 5.

5. Kết quả thực nghiệm

5.1. Hiệu năng phân đoạn (Segmentation Performance)

Chúng tôi thực hiện so sánh định lượng trên bộ dữ liệu BraTS 2020 theo hai giao thức đánh giá: kiểm định

Bảng 1

Hiệu năng phân đoạn và hiệu chuẩn trên 5-Fold Cross Validation (369 ca). **In đậm:** kết quả tốt nhất trong từng cột. Dấu “–” biểu thị Baseline không hỗ trợ tính BraTS Score do không có bản đồ bất định phân rõ.

Phương pháp	Ep.	Dice Score (%) ↑				HD95 (mm) ↓				ECE ↓	BraTS ↑
		WT	TC	ET	Mean	WT	TC	ET	Mean		
Baseline nnU-Net	50	92.53	89.92	79.07	87.17	3.76	3.69	27.34	11.60	1.536	–
EDL-nnU-Net (Ours)	50	92.06	87.98	76.00	85.35	3.88	4.21	28.88	12.32	0.616	0.902
Baseline nnU-Net	250	93.77	92.22	82.47	89.49	2.74	3.02	24.54	10.10	1.250	–
EDL-nnU-Net (Ours)	250	93.63	92.00	81.25	88.96	2.71	2.82	26.59	10.71	0.805	0.930

Bảng 2

Hiệu năng phân đoạn và hiệu chuẩn trên tập Fixed Split Test (74 ca). **In đậm:** kết quả tốt nhất trong từng cột.

Phương pháp	Ep.	Dice Score (%) ↑				HD95 (mm) ↓				ECE ↓	BraTS ↑
		WT	TC	ET	Mean	WT	TC	ET	Mean		
Baseline nnU-Net	50	92.01	89.04	83.03	88.03	5.72	4.97	13.57	8.09	1.790	–
EDL-nnU-Net (Ours)	50	91.58	88.26	82.39	87.41	4.88	3.86	12.76	7.17	1.052	0.912
Baseline nnU-Net	250	91.69	89.26	83.57	88.17	5.37	3.88	12.41	7.22	2.049	–
EDL-nnU-Net (Ours)	250	91.95	89.59	83.97	88.50	4.55	3.48	12.66	6.90	1.584	0.930

chéo 5 lần trên toàn bộ tập dữ liệu (369 ca) và kiểm thử trên tập Fixed Split độc lập (74 ca). Cấu hình suy luận sử dụng Test Time Augmentation (TTA) và cửa sổ trượt 50%.

5.1.1. Đánh giá 5-Fold Cross Validation (369 ca)

Bảng 1 trình bày kết quả đánh giá toàn diện trên 5-Fold Cross Validation, trong đó mỗi bệnh nhân đều lần lượt đóng vai trò dữ liệu kiểm thử.

Kết quả cho thấy tại cùng mốc 250 epochs, mô hình EDL-nnU-Net duy trì hiệu năng phân đoạn rất gần với Baseline (Mean Dice 88.96% so với 89.49%), trong khi đạt ECE thấp hơn đáng kể (0.805% so với 1.250%). Đặc biệt, EDL cho kết quả HD95 tốt hơn ở vùng WT (2.71 so với 2.74 mm) và TC (2.82 so với 3.02 mm), cho thấy đường biên phân đoạn mượt mà hơn tại các cấu trúc lớn.

5.1.2. Đánh giá trên tập Fixed Split Test (74 ca)

Bảng 2 trình bày kết quả trên tập kiểm thử độc lập (Fold 0 Validation), nhằm đối chiếu công bằng với các phương pháp SOTA sử dụng tập test riêng.

Trên tập Fixed Test, xu hướng trở nên rõ ràng hơn: tại mốc 250 epochs, EDL-nnU-Net vượt Baseline ở cả Mean Dice (88.50% so với 88.17%) lẫn Mean HD95 (6.90 so với 7.22 mm), đồng thời duy trì ECE thấp hơn đáng kể (1.584% so với 2.049%). Kết quả này bác bỏ lo ngại rằng việc tích hợp ước lượng bất định sẽ làm suy giảm độ chính xác phân đoạn.

5.1.3. So sánh với các phương pháp SOTA

Bảng 3 đối chiếu kết quả của phương pháp đề xuất với các kiến trúc tiên tiến nhất trên BraTS 2020.

Kết quả cho thấy phương pháp đề xuất thể hiện năng lực cạnh tranh rất mạnh so với các nghiên cứu tham chiếu. Trong thiết lập 5-Fold CV, EDL-nnU-Net đạt Mean Dice 88.96%, vượt trội so với hầu hết các phương pháp tham chiếu, đặc biệt ở khả năng khoanh vùng Whole Tumor (WT: 93.63%) và Tumor Core (TC: 92.00%). Ngay cả khi so sánh trên tập Fixed Test (88.50%), kết quả vẫn cao hơn Standard nnU-Net v1 (87.07% trên 5-Fold CV) và các phương pháp EDL trước đó.

Cần lưu ý rằng các công trình đối sánh không hoàn toàn sử dụng cùng một giao thức đánh giá, do đó các kết luận về SOTA tuyệt đối cần được diễn giải thận trọng. Tuy nhiên, sự chênh lệch lớn (> 5% Mean Dice so với các phương pháp EDL trước) vẫn cho thấy xu hướng rõ ràng về ưu thế của việc kết hợp backbone nnU-Net v2 với hàm mất mát Composite Loss đề xuất.

5.2. Kết quả định tính (Qualitative Results)

Phân tích định tính đóng vai trò quan trọng để làm rõ cách thức mô hình biểu diễn và diễn giải độ bất định ở mức voxel. Hình 3 minh họa kết quả trên một lát cắt MRI tiêu biểu (Slice 104, Bệnh nhân BRATS_019) thuộc tập Validation.


Quan sát kết quả định tính cho thấy những đặc điểm nổi bật sau:

1. Độ chính xác về hình thái: Bản đồ phân đoạn bám sát cấu trúc giải phẫu của khối u so với nhãn thực tế. Mô hình phân tách rõ ràng ba vùng chức năng: lõi hoại tử, vùng phù nề bao quanh và lõi tăng quang, ngay cả khi các vùng này có hình dạng phức tạp.
2. Khả năng giải thích thông qua Độ bất định:

Bảng 3

So sánh chỉ số Dice Score (%) với các phương pháp SOTA trên BraTS 2020. Cột “Đánh giá” ghi rõ giao thức đánh giá của từng công trình. **In đậm**: kết quả tốt nhất.

Phương pháp	WT	TC	ET	Mean Dice	Đánh giá
dResU-Net	86.60	83.57	80.04	83.40	Custom split
ADHDC-Net	89.75	83.31	78.01	83.69	Custom split
nnU-Net Ensemble	91.00	84.40	77.60	84.80	Custom split
H2NF-Net	91.30	85.50	78.80	86.20	Custom split
Standard nnU-Net v1	91.87	87.97	81.37	87.07	5-Fold CV
Energy-Based Attention	89.13	88.97	87.47	88.52	Custom split
Baseline nnU-Net v2 (Ours)	93.77	92.22	82.47	89.49	5-Fold CV
EDL-nnU-Net (Ours)	93.63	92.00	81.25	88.96	5-Fold CV
EDL-nnU-Net (Ours)	91.95	89.59	83.97	88.50	Fixed Test



Hình 3: Trực quan hóa kết quả phân đoạn và phân rã độ bất định của mô hình EDL-nnU-Net. Từ trái qua phải: (1) Ảnh MRI đầu vào; (2) Nhãn thực tế; (3) Dự đoán. Bên dưới (4) Total Uncertainty; (5) Aleatoric Uncertainty; (6) Epistemic Uncertainty. Các vùng sáng trong bản đồ bất định thể hiện mức độ không chắc chắn cao.


- Tập trung tại vùng biên: Cả hai bản đồ bất định đều đạt giá trị cao tập trung dọc theo ranh giới giữa khối u và mô lành, phản ánh đúng hiệu ứng thể tích riêng phần (partial volume effect).
- Nhận diện vùng chưa được học: Epistemic Uncertainty tập trung cục bộ tại các điểm khó, cho thấy mô hình có khả năng nhận diện các vùng đặc trưng chưa được học đầy đủ, từ đó đưa ra tín hiệu cảnh báo thay vì dự đoán sai một cách quả quyết.

5.3. Đánh giá độ tin cậy (Reliability Analysis)

Để kiểm chứng khả năng “tự nhận thức lỗi” của mô hình, chúng tôi sử dụng giao thức QU-BraTS. Bản đồ Total Uncertainty được tính bằng Entropy của phân phối dự đoán kỳ vọng từ Dirichlet posterior, nhất quán với các thiết lập chuẩn trong [9].

5.3.1. Phân tích đường cong hiệu năng – độ bất định

Hình 4 biểu diễn các đường cong AUC theo giao thức QU-BraTS cho lớp ET – vùng tổn thương quan trọng nhất nhưng cũng thách thức nhất. Ba đường cong tương ứng với ba thành phần bất định được sử dụng làm tiêu chí lọc voxel.



Hình 4: Các đường cong AUC theo giao thức QU-BraTS cho lớp Enhancing Tumor (ET) với mô hình EDL-nnU-Net 250 epochs. Đường nét liền đỏ: Total Uncertainty; nét đứt xanh lá: Aleatoric; nét chấm xanh dương: Epistemic. Đường nét đứt đen: Oracle (giới hạn trên lý thuyết).

Bảng 4

So sánh chất lượng bản đồ bất định với các phương pháp khác. (*) Giá trị trích dẫn từ [9].

Phương pháp	Mean Dice $\uparrow$	ECE (%) $\downarrow$	BraTS $\uparrow$	Ghi chú
Deep Ensemble*	0.807	1.000	0.873	Tốn N lần chi phí tính toán
MC Dropout*	0.804	0.900	0.869	Phải lấy mẫu nhiều lần
EDL (TBraTS, 200 ep.)*	0.790	1.900	0.862	Single pass
EDL (Region-based, 200 ep.)*	0.793	1.600	0.874	Single pass (74 ca test)
EDL-nnU-Net (Ours, 50 ep.)	0.853	0.616	0.902	Single pass, 5-Fold CV
EDL-nnU-Net (Ours, 250 ep.)	0.885	1.584	0.930	Single pass, Fixed Test
EDL-nnU-Net (Ours, 250 ep.)	0.890	0.805	0.930	Single pass, 5-Fold CV

Đường Dice-Retention (biểu đồ trái) cho thấy xu hướng tăng trưởng rõ rệt khi loại bỏ dần các voxel có bất định cao: chỉ số Dice tăng đơn điệu và tiệm cận đường Oracle. Điều này chứng minh cơ chế Fail-safe – mô hình gán độ bất định rất cao cho những vùng dự đoán sai. Đặc biệt, đường Aleatoric bám sát đường Total hơn so với Epistemic trên cả ba biểu đồ, gợi ý rằng phần lớn sự không chắc chắn ở vùng ET đến từ nhiều dữ liệu (ranh giới mờ giữa ET và các vùng u khác) hơn là thiếu dữ liệu huấn luyện.

Đường FTP-Retention (biểu đồ giữa) và FTN-Retention (biểu đồ phải) cho thấy khi loại bỏ các voxel bất định cao, cả tỷ lệ dự đoán dương tính sai lẫn âm tính sai đều giảm, khẳng định rằng bản đồ bất định có tương quan thực chất với lỗi phân đoạn chứ không chỉ phản ánh nhiễu ngẫu nhiên.

5.3.2. So sánh điểm số QU-BraTS với các phương pháp khác

Bảng 4 so sánh điểm số tin cậy của phương pháp đề xuất với các phương pháp SOTA. Chúng tôi trình bày song song kết quả trên cả hai giao thức đánh giá.

Khi so sánh trên cùng hệ quy chiếu tập dữ liệu (Fixed Test 74 ca), phương pháp đề xuất vượt rõ rệt Region-based EDL ở cả Mean Dice (0.885 so với 0.793) và BraTS Score (0.930 so với 0.874). Ở góc độ toàn diện

(5-Fold CV, 250 epochs), ECE đạt 0.805% – vượt cả các phương pháp tốn nhiều tài nguyên như MC Dropout (0.900%) hay Deep Ensemble (1.000%), đồng thời giữ Mean Dice ở mức 0.890.

Lưu ý về chiến lược “Force-confidence”: Chúng tôi nhận thấy việc áp dụng hậu xử lý cưỡng ép độ tự tin có thể đẩy điểm số QU-BraTS lên rất cao (ví dụ: WT đạt 0.960). Tuy nhiên, chúng tôi ưu tiên sự an toàn lâm sàng và chấp nhận điểm số thô, thay vì tạo ra “False Trust” – tình trạng nguy hiểm khi AI dự đoán sai nhưng khẳng định chắc chắn là đúng. Trừ khi có ghi chú khác, toàn bộ kết quả được báo cáo dựa trên đầu ra evidential thô (raw output).

5.4. Phân tích các xu hướng quan trọng

Dựa trên các kết quả định lượng, có thể rút ra một số nhận định quan trọng:

Mối quan hệ đánh đổi giữa số Epoch và độ hiệu chuẩn (ECE). Một xu hướng nhất quán là khi tăng số epoch từ 50 lên 250, ECE của mô hình EDL tăng nhẹ (từ 0.616% lên 0.805% trên 5-Fold CV; từ 1.052% lên 1.584% trên Fixed Test). Điều này cho thấy khi huấn luyện lâu hơn, mô hình có xu hướng trở nên tự tin hơn để tối ưu hiệu năng phân đoạn. Tuy nhiên, nhờ cơ chế Annealing Step (phạt nặng KL Divergence trong 100

epochs đầu), EDL vẫn duy trì ECE thấp hơn đáng kể so với Baseline ở mọi mốc đánh giá (ví dụ: 0.805% so với 1.250% tại 250 epochs 5-Fold; 1.584% so với 2.049% tại 250 epochs Fixed Test).

Ưu thế về độ chính xác biên (HD95) ở WT và TC. Mô hình EDL nhất quán đạt HD95 tốt hơn ở các vùng WT và TC, đặc biệt trên tập Fixed Test. Tại mốc 250 epochs, HD95 vùng WT giảm từ 5.37 mm xuống 4.55 mm, vùng TC giảm từ 3.88 mm xuống 3.48 mm. Điều này cho thấy EDL giúp giảm các dự đoán sai lệch cục bộ nằm xa ranh giới thực tế, tạo ra đường biên mượt mà hơn. Tuy vậy, lợi thế này không đồng đều trên mọi lớp và Mean HD95 tổng thể vẫn chịu ảnh hưởng mạnh từ lớp ET.

Hiệu năng trên lớp ET (Enhancing Tumor). Lớp ET tiếp tục là thành phần thách thức nhất. Trong 5-Fold CV, Dice của EDL ở lớp ET thấp hơn Baseline một chút (81.25% so với 82.47% tại 250 epochs). Tuy nhiên, trên tập Fixed Test ở cùng mốc, EDL lại vượt lên với 83.97% (so với 83.57% Baseline). Kết quả này cho thấy mặc dù ET là lớp khó, mô hình EDL vẫn thể hiện khả năng tổng quát hóa đáng chú ý trên dữ liệu chưa gặp.

Chất lượng bản đồ bất định tăng theo thời gian huấn luyện. BraTS Score tăng đều từ 0.902 (50 epochs) lên 0.930 (250 epochs) trên 5-Fold CV, và từ 0.912 lên 0.930 trên Fixed Test. Xu hướng này cho thấy khi mô hình học tốt hơn về phân đoạn, bản đồ bất định cũng tương quan tốt hơn với lỗi thực tế – độ bất định do EDL tạo ra không chỉ mang tính hình thức mà phản ánh ngày càng sát những vùng mô hình có nguy cơ dự đoán sai.

5.5. Phân tích tính bền vững (Robustness Analysis)

Trong môi trường lâm sàng thực tế, chất lượng ảnh MRI có thể bị suy giảm do chuyển động của bệnh nhân hoặc hạn chế của thiết bị. Chúng tôi tập trung phân tích sâu vào tác động của Gaussian Blur (làm mờ), vì đây là tác nhân gây ảnh hưởng nghiêm trọng nhất đến khả năng xác định đường biên khối u (Hình 5).

5.5.1. Phản ứng của Độ bất định dữ liệu (Aleatoric Uncertainty)

- Khi chi tiết cạnh bị làm mờ, bản đồ Aleatoric Uncertainty lập tức phản ứng bằng cách tăng độ sáng mạnh mẽ, đặc biệt tại ranh giới giữa khối u và mô lành.
- Dice Score giảm đáng kể (từ 0.90 xuống 0.83 cho vùng WT) khi mức mờ tăng lên Level 1.5.
- Mô hình thể hiện khả năng “tự nhận thức” tốt: thay vì cố đưa ra đường biên sắc nét một cách quá tự tin trên dữ liệu mờ, mô hình mở rộng vùng bất định, phát tín hiệu cảnh báo.

Các phân tích bổ sung với Gaussian Noise và Motion Ghosting cho thấy Aleatoric Uncertainty cũng hoạt động hiệu quả như một bộ lọc kiểm soát chất lượng (chi tiết tại Phụ lục A).

5.5.2. Phản ứng của Độ bất định mô hình (Epistemic Uncertainty)

Để khảo sát phản ứng trong các tình huống ngoài phân phối (OOD), chúng tôi chèn các dị vật nhân tạo có hình dạng và cường độ khác nhau vào ảnh MRI đầu vào (Hình 6). Kết quả cho thấy Epistemic Uncertainty chỉ thể hiện mức phản ứng rất hạn chế tại vùng dị vật.

Hiện tượng này được giải thích nhất quán: mô hình phân loại các voxel thuộc vùng dị vật vào lớp nền với xác suất rất cao, khiến entropy tổng thể giảm mạnh. Khi cả Total lẫn Aleatoric Uncertainty đều thấp, Epistemic Uncertainty (vốn là hiệu số) cũng bị suy giảm.

Quan sát này cho thấy Epistemic Uncertainty trong khuôn khổ EDL mang tính chất bảo thủ: nó chỉ tăng khi mô hình thực sự thiếu bằng chứng để đưa ra quyết định nhất quán giữa các lớp đã học. Trong trường hợp dị vật đơn giản, mô hình không “không biết” mà ngược lại tự tin cao trong việc loại trừ chúng khỏi vùng khối u.

Đây cũng là một hạn chế quan trọng của phân rã dựa trên entropy: do Aleatoric thường chiếm tỷ trọng lớn trong tổng entropy, thành phần Epistemic thường có biên độ nhỏ và khó quan sát trực quan, làm giảm khả năng sử dụng nó như một chỉ báo OOD độc lập trong các kịch bản đơn giản.

6. Hạn chế và Hướng phát triển


Mặc dù các kết quả thực nghiệm cho thấy phương pháp EDL mang lại khả năng phân rã độ bất định có ý nghĩa và nhất quán với lý thuyết thông tin, nghiên cứu này vẫn tồn tại một số hạn chế cần xem xét.

6.1. Hạn chế


(1) Chưa kiểm thử trên dữ liệu lâm sàng thực tế. Toàn bộ thí nghiệm được thực hiện trên BraTS 2020 – một bộ dữ liệu đã được chuẩn hóa cao. Mô hình chưa được đánh giá trên dữ liệu lâm sàng thực tế, nơi chất lượng ảnh MRI không đồng đều do sự khác biệt về thiết bị, giao thức chụp và đặc điểm dân số bệnh nhân. Điều này làm giảm khả năng kết luận về tính tổng quát của cả kết quả phân đoạn và bản đồ bất định.

(2) Biên độ Epistemic Uncertainty hạn chế do bản chất phân rã entropy. Trong khuôn khổ EDL, Epistemic Uncertainty là phần dư giữa tổng entropy và Aleatoric. Do Aleatoric thường chiếm tỷ trọng lớn, đặc biệt trong segmentation với dữ liệu nhiễu và ranh giới mơ hồ, thành phần Epistemic thường có giá trị nhỏ. Đây là hạn chế mang tính bản chất của phương pháp phân rã dựa trên lý thuyết thông tin, thay vì vấn đề của quá trình huấn luyện.

Robustness Analysis: Noise Impact - BRATS_019 (Slice 54)



Hình 5: Phân tích tác động của độ mờ (Gaussian Blur) đối với độ bất định trên bệnh nhân BRATS_019 (Slice 104). **Hàng dọc:** Mức độ làm mờ tăng dần (Level 0.0 đến 1.5). **Các cột:** (1) Ảnh đầu vào; (2) Nhãn thực tế; (3) Dự đoán; (4) Total Uncertainty; (5) Aleatoric; (6) Epistemic. Khi ảnh mờ đi, Dice giảm mạnh (WT: 0.90 $\rightarrow$ 0.83), đồng thời Aleatoric sáng rực tại đường biên.




Hình 6: Phân tích OOD với dị vật nhân tạo trên bệnh nhân BRATS_012 (Slice 119). Vùng bên trong dị vật hầu như không kích hoạt Epistemic Uncertainty và được mô hình phân loại nhất quán là nền (background).

(3) Thiết kế dị vật nhân tạo còn đơn giản. Các thí nghiệm OOD sử dụng dị vật có hình dạng và cường độ đơn giản, khiến mô hình dễ dàng phân loại chúng là nền với độ tin cậy cao. Điều này hạn chế khả năng kích

hoạt Epistemic Uncertainty và chưa phản ánh đầy đủ các dạng OOD phức tạp trong thực tế.

(4) Xu hướng tăng ECE khi huấn luyện dài hạn. Mặc dù EDL luôn duy trì ECE thấp hơn Baseline, ECE vẫn tăng nhẹ khi tăng epoch (từ 0.616% lên 0.805%



Hình 7: (Trái) Phản ứng với Nhiễu hạt (Gaussian Noise): Bản đồ Aleatoric tăng sáng dạng “đốm” rải rác trên toàn bộ nhu mô não, phản ánh độ tin cậy của dữ liệu giảm sút trên toàn cục (thường gặp ở máy MRI SNR thấp). **(Phải)** Phản ứng với hiện tượng Bóng ma (Motion Ghosting): Bản đồ Aleatoric bắt trọn các vết bóng lặp lại theo chiều pha, gợi ý tiềm năng ứng dụng như công cụ cảnh báo kỹ thuật viên chụp lại cho bệnh nhân.

trên 5-Fold CV). Việc kiểm soát tối ưu mối quan hệ giữa hiệu năng phân đoạn và độ hiệu chuẩn theo thời gian huấn luyện vẫn là một bài toán mở.

6.2. Hướng phát triển

(1) Mở rộng đánh giá trên dữ liệu lâm sàng thực tế. Kiểm thử mô hình trên các tập dữ liệu MRI thu thập trực tiếp từ bệnh viện, với mức độ nhiễu và đa dạng cao hơn, cho phép đánh giá thực chất vai trò của Aleatoric Uncertainty như cơ chế kiểm soát chất lượng ảnh, cũng như hành vi của Epistemic Uncertainty dưới domain shift thực sự.

(2) Kết hợp EDL với các phương pháp Bayesian. Các phương pháp ensemble có thể được sử dụng như chuẩn tham chiếu cho Epistemic Uncertainty. Việc kết hợp hoặc so sánh EDL với ensemble, dù có chi phí cao hơn, có thể làm rõ mối quan hệ và sự bổ sung giữa hai cách tiếp cận.

(3) Thiết kế kịch bản OOD phức tạp hơn. Xây dựng các kịch bản OOD mang tính sinh học hơn, chẳng hạn dị vật có kết cấu giống mô u hoặc cường độ không đồng nhất, được kỳ vọng sẽ kích hoạt Epistemic Uncertainty rõ ràng hơn.

(4) Chuẩn hóa riêng thành phần Epistemic Uncertainty. Nghiên cứu các chiến lược chuẩn hóa hoặc tái tỉ lệ (rescaling) riêng cho Epistemic Uncertainty, cũng như xây dựng chỉ số định lượng dành riêng cho phát hiện OOD, có thể nâng cao khả năng diễn giải và ứng dụng thực tiễn.

(5) Tối ưu chiến lược Annealing. Tìm kiếm các lịch trình annealing thích ứng (adaptive annealing schedules) cho hệ số KL divergence, nhằm cân bằng tốt hơn giữa tối ưu Dice và duy trì hiệu chuẩn trong suốt quá trình huấn luyện dài hạn.

A. Phân tích bổ sung về tính bền vững

Bên cạnh Gaussian Blur, chúng tôi cũng đánh giá mô hình trên hai loại nhiễu phổ biến khác là nhiễu hạt và nhiễu bóng ma (Hình 7):

Tài liệu

- [1] O. Ronneberger, P. Fischer, T. Brox, U-net: Convolutional networks for biomedical image segmentation, Medical Image Computing and Computer-Assisted Intervention (MICCAI) (2015).
- [2] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, K. H. Maier-Hein, nnu-net: A self-configuring method for deep learning-based biomedical image segmentation, Nature Methods (2021).
- [3] S. Bakas, M. Reyes, A. Jakab, S. Bauer, M. Rempfler, A. Crimi, R. T. Shinohara, C. Berger, S. M. Ha, G. Erus, et al., Identifying the best machine learning algorithms for brain tumor segmentation, progression assessment, and overall survival prediction in the brats challenge, arXiv preprint arXiv:1811.02629 (2018).
- [4] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, On calibration of modern neural networks, in: International Conference on Machine Learning (ICML), 2017, pp. 1321–1330.
- [5] A. Kendall, Y. Gal, What uncertainties do we need in bayesian deep learning for computer vision?, Advances in Neural Information Processing Systems (NeurIPS) (2017).
- [6] M. Sensoy, L. Kaplan, M. Kandemir, Evidential deep learning to quantify classification uncertainty, Advances in Neural Information Processing Systems (NeurIPS) (2018).
- [7] Y. Gal, Z. Ghahramani, Dropout as a bayesian approximation: Representing model uncertainty in deep learning, International Conference on Machine Learning (ICML) (2016).
- [8] K. Zou, X. Chen, Y. Yuan, X. Shen, M. Wang, H. Fu, Tbrats: Trusted brain tumor segmentation, International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI) (2022).
- [9] H. Li, Y. Nan, J. Del Ser, G. Yang, Region-based evidential deep learning to quantify uncertainty and improve robustness of brain tumor segmentation, Neural Computing and Applications (2022).
- [10] B. Lakshminarayanan, A. Pritzel, C. Blundell, Simple and scalable predictive uncertainty estimation using deep ensembles, in: Advances in Neural Information Processing Systems (NeurIPS), volume 30, 2017.
- [11] T. Nair, D. Precup, D. L. Arnold, T. Arbel, Exploring uncertainty measures in deep networks for multiple sclerosis lesion detection and segmentation, Medical Image Analysis 59 (2020) 101557.
- [12] F. Milletari, N. Navab, S.-A. Ahmadi, V-net: Fully convolutional neural networks for volumetric medical image segmentation, in: International Conference on 3D Vision (3DV), 2016, pp. 565–571.

- [13] A. Malinin, M. Gales, Predictive uncertainty estimation via prior networks, in: Advances in Neural Information Processing Systems (NeurIPS), volume 31, 2018.
- [14] R. Mehta, A. Filos, U. Baid, et al., Quantifying uncertainty in brain tumor segmentation: The qu-brats 2020 challenge, in: International MICCAI Brainlesion Workshop, Springer, 2020, pp. 3–14.