

Phân đoạn Khối u não Đa phương thức Tin cậy sử dụng Evidential Deep Learning

Khắc phục hạn chế của Softmax và Cải thiện Độ an toàn Lâm sàng

Nguyễn Tất Bảo Thiện (GVHD), Lương Đắc Nguyên, Bùi Trương Thái Sơn, Ung Hoàng Long

Trường Đại Học Công Nghệ Thông Tin, ĐHQG TP.HCM - Khoa Khoa Học và Kỹ Thuật Thông Tin

Ngày 21 tháng 1 năm 2026

Nội dung trình bày

- 1 Giới thiệu & Đặt vấn đề
- 2 Tổng quan & Phân tích (Related Work)
- 3 Cơ sở Toán học & Hàm Loss
- 4 Phân rã Độ bất định (Uncertainty Decomposition)
- 5 Kết quả Thực nghiệm
- 6 Kết luận & Hướng phát triển

Bối cảnh & Vấn đề Nghiên cứu (Problem Statement)

- **Bối cảnh:**

- Phân đoạn khối u não tự động (Brain Tumor Segmentation) là then chốt trong chẩn đoán và điều trị.
- Các mô hình Deep Learning hiện đại (U-Net, nnU-Net) đạt độ chính xác cao (Dice Score > 90%).

- **Vấn đề tồn tại ("Nỗi đau" của bác sĩ):**

- **Hộp đen (Black-box):** Chỉ đưa ra kết quả phân đoạn, không kèm mức độ tin cậy.
- **Tự tin thái quá (Overconfidence):** Hàm Softmax thường "khẳng định chắc chắn" ngay cả khi dự đoán sai (với dữ liệu lạ/nhiều).

Câu hỏi nghiên cứu

Làm thế nào để xây dựng hệ thống AI vừa chẩn đoán chính xác, vừa biết **"cảnh báo an toàn"** khi gặp ca bệnh khó hoặc dữ liệu kém?

Tại sao Softmax không tối ưu? (The Limit of Softmax)

- **Cơ chế Softmax:**

- Chỉ cung cấp ước lượng điểm (Point Estimate).
- Tổng xác suất luôn bị ép bằng 1.

- **Hệ quả nguy hiểm:**

- Không phân biệt được "*Không chắc chắn do nhiễu*" (Aleatoric) và "*Không chắc chắn do thiếu kiến thức*" (Epistemic).

- **Ví dụ:** Ảnh nhiễu hoàn toàn (out of domain-OOD)
→ Softmax vẫn có thể trả về xác suất 0.99 cho một lớp ngẫu nhiên.

Nhu cầu cấp thiết

Cần phương pháp mới có khả năng **định lượng và phân tách độ bất định** (Uncertainty Quantification).

Giải pháp đề xuất - Evidential Deep Learning (EDL)

- **Ý tưởng cốt lõi:**

- Thay thế Softmax bằng **Lý thuyết Bằng chứng (Dempster-Shafer Theory)**.
- Đầu ra là một **Phân phối xác suất (Dirichlet Distribution)** thay vì giá trị đơn lẻ.

- **Ưu điểm vượt trội (Selling Points):**

- ① **Độ tin cậy cao:** Phát hiện mẫu dữ liệu lạ (OOD) qua Epistemic Uncertainty.
- ② **Hiệu quả tính toán:** Chỉ cần **một lần chạy (Single-pass)**, nhanh hơn nhiều so với Bayesian/Ensemble (cần chạy nhiều lần).
- ③ **Dễ tích hợp:** Nhúng trực tiếp vào nnU-Net mà không thay đổi cấu trúc mạng.

Các công trình Nghiên cứu Chính (Key Literature)

Chúng tôi xây dựng đồ án dựa trên sự kế thừa và phân tích 4 công trình cốt lõi sau:

① **Evidential Deep Learning to Quantify Classification Uncertainty**

- *NeurIPS 2018* | **1619 citations**
- → *Bài báo nền tảng (Foundation)*: Đề xuất lý thuyết EDL thay thế Softmax.

② **QU-BraTS: MICCAI BraTS 2020 Challenge on Quantifying Uncertainty...**

- *J. Mach. Learn. Biomed. Imaging 2022* | **84 citations**
- → *Tiêu chuẩn (Benchmark)*: Cung cấp bộ metric chuẩn (AUC, ranking) để đánh giá độ tin cậy.

③ **TBraTS: Trusted Brain Tumor Segmentation**

- *MICCAI 2022* | **98 citations**
- → *Baseline 1*: Ứng dụng EDL vào y sinh (nhưng dùng công thức Vacuity đơn giản).

④ **Region-based evidential deep learning to quantify uncertainty...**

- *Neural Computing Applications 2023* | **60 citations**
- → *Baseline 2*: Cố gắng cải thiện Robustness bằng Region-loss (nhưng khó hội tụ).

Tổng quan các phương pháp tiếp cận

Nhóm 1: Bayesian (Tiêu chuẩn cũ)

- **Đại diện:** MC Dropout, Deep Ensembles.
- **Cơ chế:** Suy luận nhiều lần ($N \geq 10$) để tính phương sai.
- **Nhược điểm chí mạng:**
 - Chi phí tính toán khổng lồ.
 - *Ví dụ:* Chạy inference trên NVIDIA GeForce RTX 3090 GPUs thì MC-Dropout mất $\sim 63s$ /ca não 3D.

Nhóm 2: Evidential Deep Learning (Mới)

- **Đại diện:** TBraTS (2022), Region-based EDL (2023).
- **Ưu điểm:**
 - Nhanh (Single-pass, $\sim 3s$).
 - Mô hình hóa trực tiếp qua phân phối Dirichlet.
- **Hạn chế:** Vẫn tồn tại vấn đề về định nghĩa toán học và hiệu năng thực tế.

Phân tích hạn chế của TBraTS (Zou et al., 2022)

- **Vấn đề 1: Công thức độ bất định "ngây thơ"**

- Định nghĩa Vacuity: $u = \frac{K}{S}$ (K : số lớp, S : tổng bằng chứng).
- **Hệ quả:** Chỉ đo Epistemic (thiếu dữ liệu), **bỏ qua Aleatoric (nhiều)**.

Ví dụ phản biện (Counter-example)

- Xét voxel tại **biên khối u** (mờ/nhiều):
- Mô hình tìm thấy nhiều bằng chứng mâu thuẫn: $\alpha = [50, 50] \rightarrow S = 100$ (Rất lớn).
- Theo công thức TBraTS: $u = \frac{2}{100} = 0.02$ (**Rất thấp**).
- $\rightarrow$ **Kết luận sai:** Mô hình báo "Rất tự tin" ngay tại vùng nhiễu loạn cần cảnh báo.

Phân tích hạn chế của Region-based EDL (Li et al., 2023)

- **Vấn đề 1: Hiệu năng phân đoạn chưa tối ưu**

- Hàm loss phức tạp (Region-based + KL) gây khó tối ưu hóa.
- Dice Score trung bình (WT) chỉ đạt ~ 0.791 (so với ~ 0.91 của chúng tôi).

- **Vấn đề 2: Quy trình huấn luyện**

- Chỉ train trong **200 Epochs** (chưa đủ để nnU-Net hội tụ, chuẩn là 1000).

- **Vấn đề 3: Định lượng "nhập nhằng"**

- Dùng **Entropy** làm thước đo duy nhất.
- **Hệ quả:** Không phân biệt được lỗi do ảnh xấu (Aleatoric) hay do mô hình chưa học (Epistemic).


Đề xuất của Đồ án - Lắp đầy khoảng trống

- Chúng tôi **không** tạo ra kiến trúc mới phức tạp, mà tối ưu hóa kiến trúc chuẩn (nnU-Net) với lý thuyết EDL chính thống.

Đặc điểm	TBraTS (2022)	Region-based (2023)	Đề xuất (Ours)
Công thức UQ	$u = K/S$ (Chỉ Epistemic)	Entropy (Gộp chung)	Decomposition (Tách biệt)
Hiệu năng (Dice)	~ 0.79 (BraTS 20)	~ 0.793 (BraTS 20)	~ 0.91 (BraTS 20)
Tiêu chuẩn	ECE, UEO	ECE, UEO	QU-BraTS Standard
Mục tiêu	Robustness	Robustness	Clinical Reliability

Bảng: Bảng so sánh chiến lược và hiệu năng giữa các phương pháp

Minh họa Trực quan: Tại sao cần Phân rã? (Visual Demo)



Minh chứng cho khả năng "Tách biệt"(Decomposition)

Kết quả thực tế trên ca bệnh BraTS_011 (Dice 95%) cho thấy sự rạch ròi:

- **Cột 3 (Prediction):** Phân đoạn chính xác khối u (Vàng/Đỏ).
- **Cột 4 (Aleatoric):** Sáng rực ở **viên khối u**. → Mô hình báo: *"Chỗ này ảnh mờ, tôi không chắc chắn về ranh giới."*
- **Cột 5 (Epistemic):** Tách biệt hoàn toàn, chỉ tập trung vào các vùng nghi ngờ thiếu kiến thức mô hình.

Giới thiệu Bộ dữ liệu (BraTS 2020)

- **Dữ liệu:** Multimodal Brain Tumor Segmentation Challenge 2020.
- **Đa phương thức (4 loại MRI):**
 - T1, T1ce, T2, FLAIR.
- **Nhãn phân đoạn (3 vùng u):**
 - 1 **NCR/NET:** Hoại tử (Label 1).
 - 2 **ED:** Phù nề (Label 2).
 - 3 **ET:** Ngấm thuốc (Label 3) - *Quan trọng lâm sàng.*

Thách thức chính

- **Mất cân bằng dữ liệu:** Khối u chỉ chiếm $< 2\%$ thể tích não.
- **Nhiều biên:** Ranh giới mờ nhạt $\rightarrow$ Môi trường lý tưởng kiểm thử Aleatoric Uncertainty.

Mô hình hóa Bằng chứng (Evidential Modeling Framework)

- **Nguyên lý:** Thay vì ép đầu ra vào $[0, 1]$ (Softmax), ta mô hình hóa **Bằng chứng (Evidence)** để xây dựng một Phân phối Dirichlet.

Quy trình tính toán tại mỗi Voxel

- 1 **Logits (z):** Đầu ra thô từ mạng nnU-Net.
- 2 **Evidence (e):** Dùng hàm Softplus để đảm bảo không âm:

$$e_{ik} = \ln(1 + \exp(z_{ik})) \quad (1)$$

- 3 **Tham số Dirichlet (α):** $\alpha_{ik} = e_{ik} + 1$
- 4 **Xác suất kỳ vọng ($\hat{p}$):** Giá trị trung tâm dùng để phân đoạn:

$$\hat{p}_{ik} = \frac{\alpha_{ik}}{S_i} \quad \text{với } S_i = \sum_k \alpha_{ik} \text{ (Tổng sức mạnh)} \quad (2)$$

Hàm Mất mát Đề xuất (Proposed Composite Loss)

Để mô hình học được cả "Độ chính xác" và "Độ khiêm tốn", chúng tôi sử dụng hàm Loss tổng hợp:

$$\mathcal{L}_{Total} = \underbrace{\mathcal{L}_{Bayes}}_{\text{Accuracy}} + \lambda_t \cdot \underbrace{\mathcal{L}_{KL}}_{\text{Reliability}} + \underbrace{\mathcal{L}_{Dice}(\alpha/S)}_{\text{Segmentation}} \quad (3)$$

- **Bayes Risk ($\mathcal{L}_{Bayes}$):** Tối ưu hóa xác suất đúng dựa trên phân phối Dirichlet (dùng hàm Digamma ψ).
- **KL Divergence ($\mathcal{L}_{KL}$):** Đóng vai trò *Regularizer*.
 - Phạt mô hình nếu gán bằng chứng cao cho dự đoán sai.
 - Ép phân phối về Uniform (Bất định tối đa) tại vùng lỗi.
- **Dice Loss ($\mathcal{L}_{Dice}(\alpha/S)$):**
 - Được tính trực tiếp trên xác suất kỳ vọng $\hat{p} = \alpha/S$.
 - **Ưu điểm:** Đảm bảo sự **nhất quán** (Consistency) giữa luồng dự đoán và luồng huấn luyện, giúp giữ vững hiệu năng phân đoạn ngang ngửa SOTA.

Tại sao Hàm Loss này ưu việt? (Comparative Analysis)

Phương pháp	Công thức Loss	Vấn đề (Nhược điểm)
TBraTS (2022)	$\mathcal{L}_{Bayes} + \mathcal{L}_{KL} + \mathcal{L}_{SoftmaxDice}$	Mất nhất quán: Dùng 2 luồng (Dirichlet & Softmax). Gradient không tập trung tối ưu α .
Region-based (2023)	$\mathcal{L} = 1 - \frac{2}{K} \sum \frac{\sum y \hat{p}}{\underbrace{\sum (y^2 + \hat{p}^2) + \frac{\hat{p}(1 - \hat{p})}{S + 1}}_{\text{Var}(p)}}$	Phức tạp quá mức: Đưa thành phần Var(p) vào mẫu số. → Gradient phức tạp, khó hội tụ.
Đề xuất (Ours)	$\mathcal{L}_{Bayes} + \mathcal{L}_{KL} + \mathcal{L}_{Dice}(\alpha/S)$	Đơn giản & Nhất quán: Dùng trực tiếp α/S cho mọi thành phần. → Dice đạt ~ 0.91 .

Kết luận chiến lược

Sự phức tạp về toán học không phải lúc nào cũng mang lại hiệu quả tốt nhất.

Tại sao phải Phân rã? (The Need for Decomposition)

Vấn đề của TBrATS ($u = K/S$)

- Chỉ đo lường sự thiếu hụt bằng chứng (Epistemic).
- Lỗi hồng:** Tại biên khối u (nhiều $\rightarrow$ bằng chứng mâu thuẫn nhưng S cao) $\rightarrow$ Báo "**An toàn**" (Sai lầm nguy hiểm).

Vấn đề của Entropy ($H(\hat{p})$)

- Đây là Total Uncertainty (Gộp chung).
- Hạn chế:** Bác sĩ không biết lỗi do ảnh xấu (chấp nhận được) hay do mô hình "ngu" (cần can thiệp).

Giải pháp: Áp dụng *Lý thuyết Thông tin* để tách biệt:

- Aleatoric:** Do dữ liệu (Nhiều, Mờ).
- Epistemic:** Do mô hình (Dữ liệu lạ OOD).

Cơ chế Toán học (Mathematical Formulation)

Chúng tôi mô hình hóa dự đoán dưới dạng một **đám mây xác suất**, cho phép phân rã đẳng thức sau:

$$\underbrace{\mathcal{I}[y, \theta]}_{\text{Epistemic}} = \underbrace{H[\mathbb{E}[p]]}_{\text{Total}} - \underbrace{\mathbb{E}[H[p]]}_{\text{Aleatoric}} \quad (4)$$

- ❶ **Total Uncertainty:** Entropy của xác suất trung bình.

$$\mathcal{U}_{Total} = - \sum \hat{p}_k \ln \hat{p}_k \quad (\text{Sự hỗn loạn của quyết định cuối})$$


- ❷ **Aleatoric Uncertainty:** Trung bình Entropy của từng điểm (dùng hàm Digamma ψ).

$$\mathcal{U}_{Aleatoric} = \sum \hat{p}_k (\psi(S + 1) - \psi(\alpha_k + 1)) \quad (\text{Độ nhiễu dữ liệu})$$

- ❸ **Epistemic Uncertainty:** Phần dư của phép trừ.

- Đo lường sự phân tán của đám mây $\rightarrow$ Chỉ dấu cho dữ liệu lạ (OOD).

Tại sao $\mathbb{E}[H(p)]$ đại diện cho Nhiễu Dữ liệu?



1. Góc nhìn Hình học (Visual)

• Hình giữa (High Aleatoric):

- Đám mây điểm **co cụm chặt** ở trung tâm.
- → Sự "Lưỡng lự" đồng nhất.

• Hình phải (High Epistemic):

- Đám mây điểm **tỏa ra** bám sát các góc.
- → Dự đoán "Cực đoan" mâu thuẫn.

2. Tại sao là $\mathbb{E}[H(p)]$?

Aleatoric Uncertainty là trung bình độ hỗn loạn của từng mẫu thử.

• Khi dữ liệu bị nhiễu (Biên giới):

• ⇒ Kỳ vọng Entropy **CAO**.

• Khi dữ liệu lạ (OOD):

• ⇒ Kỳ vọng Entropy **THẤP**.

So sánh Chiến lược (Strategic Comparison)

Trường hợp	Đặc điểm Dữ liệu	TBraTS (K/S)	Ours (Decomposition)
Biên khối u	Ảnh mờ, nhiều bằng chứng mâu thuẫn (α cao đều)	Thấp (Sai) → Bỏ sót cảnh báo	Aleatoric Cao → "Ảnh chỗ này mờ"
Dị vật / OOD	Ảnh lạ, chưa từng thấy (α rất thấp)	Cao (Đúng)	Epistemic Cao → "Tôi chưa thấy bao giờ!"

Ý nghĩa lâm sàng

Sự phân biệt rạch ròi này giúp bác sĩ xác định được nguyên nhân lỗi:

- **Aleatoric cao:** Cần chụp lại ảnh hoặc chấp nhận rủi ro biên.
- **Epistemic cao:** Cần hội chẩn chuyên sâu (ca bệnh hiếm).

Thiết lập Thực nghiệm (Experimental Setup)

Cấu hình Huấn luyện

- **Dữ liệu:** Tập Validation **BraTS 2020** (74 ca).
- **Mô hình:** nnU-Net (3D Full Resolution).
- **Hyperparameters:**
 - Epochs: 50 (Hội tụ nhanh).
 - Optimizer: SGD + Nesterov momentum.
- **Segmentation Metrics:**
 - Dice Score ($\uparrow$ tốt).
 - Hausdorff Distance 95% ($\downarrow$ tốt).

Tiêu chuẩn Đánh giá Độ tin cậy (QU-BraTS)

Công thức tổng hợp:

$$Score = \frac{AUC_{Dice} + (1 - AUC_{FTP}) + (1 - AUC_{FTN})}{3}$$

Giải thích:

- AUC_{Dice} : Khuyến khích Dice cao tại các ngưỡng độ tin cậy cao.
- $1 - AUC_{FTP}$: Phạt nếu mô hình tự tin sai vào vùng nền (False Positive).
- $1 - AUC_{FTN}$: Phạt nếu mô hình tự tin bỏ sót khối u (False Negative).

→ **Score** $\in [0, 1]$: **Càng cao càng tốt.**

Hiệu năng Phân đoạn (1/2): Dice Score

Mục tiêu: Chứng minh việc thêm EDL không làm hỏng khả năng phân đoạn của nnU-Net.

Bảng: So sánh Dice Score trên tập Validation (BraTS 2020) - 50 epochs - fold 0

Phương pháp	WT (Whole)	TC (Core)	ET (Enhancing)
Baseline (nnU-Net)	0.9188	0.8912	0.7969
Ours (EDL-nnU-Net)	0.9259	0.8964	0.8050

Nhận xét quan trọng

- Mô hình EDL đạt **Dice Score cao hơn** Baseline ở cả 3 vùng khối u.
- **Ý nghĩa:** Bác bỏ lo ngại rằng hàm loss phức tạp sẽ làm giảm độ chính xác (Vấn đề mà Region-based EDL gặp phải).

Hiệu năng Phân đoạn (2/2): Hausdorff Distance (HD95)

Chỉ số HD95: Đo lường sai số biên dạng (khoảng cách lớn nhất tại 95% điểm ảnh). *Giá trị càng thấp càng tốt (↓).*

Bảng: So sánh HD95 (mm) trên tập Validation (BraTS 2020) - 50 epochs - fold 0

Phương pháp	WT (↓)	TC (↓)	ET (↓)
Baseline (nnU-Net)	5.6808	3.4619	3.1246
Ours (EDL-nnU-Net)	5.4782	3.4807	3.2738

Phân tích Chi tiết

- **Whole Tumor (WT):** Mô hình EDL cải thiện đáng kể sai số biên dạng (giảm $\sim 0.2\text{mm}$).
- **TC & ET:** Kết quả tương đương (chênh lệch rất nhỏ $< 0.15\text{mm}$, không có ý nghĩa thống kê).
- **Kết luận:** Việc tích hợp mô đun ước lượng độ bất định vẫn duy trì được cấu trúc hình học của khối u ngang ngửa với SOTA.

Đánh giá Độ tin cậy (Reliability Analysis)


Kết quả QU-BraTS Score:

• WT: 0.9145 | TC: 0.9077 | ET: 0.8919

Chiến lược "Force-confidence"

Khi áp dụng hậu xử lý ép tự tin, điểm số tăng vọt lên: **WT: 0.9604 | TC: 0.9475 | ET: 0.9180**.

→ Chúng tôi chọn giữ nguyên độ bất định tự nhiên để đảm bảo **An toàn Lâm sàng** thay vì chỉ tối ưu điểm số thi đấu.



Hình: Đường cong Dice vs. Uncertainty


Phân tích Aleatoric (1/3): Nhiễu Hạt (Gaussian Noise)

Thiết lập Thí nghiệm

- **Giả lập:** Tín hiệu cộng hưởng từ kém (Low SNR), thường gặp ở các máy MRI đời cũ hoặc cắt lớp mỏng.
- **Cơ chế:** Thêm nhiễu Gaussian ngẫu nhiên vào toàn bộ ảnh.

Quan sát Ý nghĩa

- **Hiện tượng:** Bản đồ Aleatoric tăng sáng dạng "đốm" rải rác trên toàn bộ nhu mô não và vùng nền.
- **Kết luận:** Mô hình nhận biết được độ tin cậy của dữ liệu đầu vào đang giảm sút tổng thể, không tập trung vào một vùng cụ thể nào.



Hình: Phản ứng với Nhiễu hạt (Noise)


Phân tích Aleatoric (2/3): Làm mờ (Gaussian Blur)

Thiết lập Thí nghiệm

- **Giả lập:** Lỗi do độ phân giải thấp hoặc xử lý làm mịn ảnh quá mức (smoothing).
- **Cơ chế:** Áp dụng bộ lọc Gaussian Blur làm mất chi tiết cạnh.

Quan sát Ý nghĩa

- **Hiện tượng:** Độ bất định tăng vọt (sáng rực) tại các **đường biên (boundaries)** giữa khối u và não lành.
- **Kết luận:** Đây là tính năng quan trọng nhất. Mô hình cảnh báo: *"Tôi thấy khối u ở đây, nhưng tôi không chắc chắn ranh giới nó nằm chính xác ở đâu do ảnh quá mờ"*.



Hình: Phản ứng với Ảnh mờ (Blur)


Phân tích Aleatoric (3/3): Bóng ma (Motion Ghosting)

Thiết lập Thí nghiệm

- **Giả lập:** Bệnh nhân cử động (lắc đầu, ho) trong quá trình chụp MRI.
- **Cơ chế:** Tạo các bản sao mờ của cấu trúc não lặp lại theo chiều pha.

Quan sát Ý nghĩa


- **Hiện tượng:** Bản đồ Aleatoric bắt trọn các vết bóng ma (artifacts) mà mắt thường đôi khi khó thấy.
- **Kết luận:** Hệ thống hoạt động như một bộ **Quality Control (QC)**. Nếu Aleatoric quá cao theo dạng này → Đề xuất kỹ thuật viên chụp lại cho bệnh nhân.



Hình: Phản ứng với Chuyển động (Ghosting)

Phân tích Định tính: Dữ liệu Lạ (Epistemic - OOD)

- **Thí nghiệm:** Giả lập dị vật (khối hộp trắng/flip ảnh).
- **Quan sát:**
 - Bản đồ **Aleatoric** tối (vì ảnh rõ nét).
 - Bản đồ **Epistemic** sáng rực tại vị trí dị vật.
- **Kết luận:** Đây là "**Cảnh báo An toàn**". Mô hình thừa nhận sự "thiếu hiểu biết" trước ca bệnh lạ.



Tổng kết Đóng góp (Summary of Contributions)

Đề án đã giải quyết thành công câu hỏi nghiên cứu đặt ra ban đầu: "*Làm thế nào để AI biết nói 'Tôi không chắc'?*"


- ➊ **Về Kiến trúc:** Tích hợp thành công **Evidential Deep Learning** vào **nnU-Net** mà không làm phá vỡ cấu trúc chuẩn, giữ vững hiệu năng phân đoạn SOTA (Dice ~ 0.91).
- ➋ **Về Lý thuyết:** Đề xuất phương pháp **Phân rã Độ bất định (Uncertainty Decomposition)** dựa trên Lý thuyết Thông tin.
 - Khắc phục điểm mù của TBrATS ($u = K/S$).
 - Tách biệt rõ ràng Nhiều dữ liệu (Aleatoric) và Lỗi mô hình (Epistemic).
- ➌ **Về Thực nghiệm:** Chứng minh khả năng phát hiện mẫu dữ liệu lạ (OOD) và cảnh báo an toàn tin cậy thông qua các chỉ số QU-BraTS.

Ý nghĩa Lâm sàng (Clinical Implications)

Hệ thống không chỉ là một công cụ phân đoạn, mà đóng vai trò như một **"Trợ lý AI Cần trọng"**:

Cơ chế "Đèn giao thông" cho Bác sĩ

- **Độ bất định thấp: An toàn.** Bác sĩ có thể tin tưởng kết quả phân đoạn.
- **Aleatoric cao: Cảnh báo Ảnh.** Vùng biên mờ hoặc ảnh nhiễu. Bác sĩ cần kiểm tra kỹ vùng biên giới.
- **Epistemic cao: BÁO ĐỘNG.** Ca bệnh dị biệt hoặc lỗi kỹ thuật. Cần hội chẩn chuyên gia hoặc chụp lại MRI.



Hạn chế & Hướng phát triển (Future Work)

- **Hạn chế hiện tại:**

- Việc tính toán Uncertainty Decomposition tốn thêm chi phí bộ nhớ VRAM.
- Chưa kiểm thử trên dữ liệu lâm sàng thực tế (Real-world Clinical Data) ngoài tập BraTS.

- **Kế hoạch tương lai:**

- ➊ **Tối ưu hóa:** Áp dụng kỹ thuật *Knowledge Distillation* để giảm nhẹ mô hình, hướng tới chạy real-time.
- ➋ **Mở rộng đa nhiệm:** Tích hợp thêm module dự báo sinh tồn (Survival Prediction) dựa trên độ bất định.
- ➌ **Active Learning:** Sử dụng Epistemic Uncertainty để tự động chọn lọc các ca bệnh khó nhằm huấn luyện lại mô hình (Human-in-the-loop).

Cảm ơn Quý Thầy/Cô và các bạn đã lắng nghe!