

Highlights

Accuracy-Preserving Uncertainty Decomposition for Brain Tumor Segmentation with Evidential nnU-Net

Luong Dac Nguyen, Bui Truong Thai Son, Ung Hoang Long, Thien B. Nguyen-Tat

- Tích hợp Evidential Deep Learning vào nnU-Net giúp định lượng độ bất định mà không tốn chi phí lấy mẫu (sampling).
- Đề xuất hàm mất mát mới kết hợp Bayes Risk và Dice Loss, khắc phục sự sụt giảm hiệu năng ở các phương pháp EDL trước đây.
- Phân rã thành công độ bất định thành Aleatoric (nhiều ảnh) và Epistemic (dữ liệu lạ), hỗ trợ diễn giải lâm sàng.
- Đạt hiệu năng phân đoạn cao (Dice WT 0.9259) trên tập dữ liệu BraTS 2020.

Accuracy-Preserving Uncertainty Decomposition for Brain Tumor Segmentation with Evidential nnU-Net

Luong Duc Nguyen^{a,b}, Bui Truong Thai Son^{a,b}, Ung Hoang Long^{a,b} and Thien B. Nguyen-Tat^{a,b,*}

^aUniversity of Information Technology, Ho Chi Minh City, Vietnam

^bVietnam National University, Ho Chi Minh City, Vietnam

ARTICLE INFO

Keywords:

Brain tumor segmentation
Uncertainty decomposition
nnU-Net
Evidential Deep Learning
BraTS

Tóm tắt nội dung

Phân đoạn khối u não từ ảnh cộng hưởng từ (MRI) bằng học sâu đã đạt được hiệu năng cao với các kiến trúc chuẩn hóa như nnU-Net, tuy nhiên độ tin cậy của dự đoán vẫn là một thách thức lớn. Nhiều phương pháp ước lượng bất định hiện nay thường dẫn đến sự suy giảm hiệu năng phân đoạn, tạo ra sự đánh đổi giữa độ chính xác và khả năng ước lượng bất định.

Trong nghiên cứu này, chúng tôi đề xuất một khung Evidential Deep Learning tích hợp với nnU-Net, trong đó một hàm mất mát mới được thiết kế nhằm tối ưu đồng thời quá trình phân đoạn và học bằng chứng. Phương pháp đề xuất giúp cải thiện chỉ số Dice ngay cả khi tích hợp cơ chế ước lượng bất định và chỉ yêu cầu số epoch huấn luyện hạn chế. Đồng thời, mô hình cho phép phân rã bất định dự đoán thành hai thành phần là aleatoric và epistemic, cung cấp khả năng diễn giải rõ ràng hơn.

Các thực nghiệm trên bộ dữ liệu BraTS 2020, bao gồm các kịch bản nhiễu và ngoài phân phối, cho thấy phương pháp đề xuất đạt hiệu năng phân đoạn ổn định hơn và bản đồ bất định có giá trị thực tiễn cao.

1. Introduction

Phân đoạn khối u não (Brain Tumor Segmentation) là một thành phần quan trọng trong chẩn đoán và lập kế hoạch điều trị các bệnh lý thần kinh. Việc xác định chính xác vị trí và hình thái của khối u giúp hỗ trợ bác sĩ trong việc lựa chọn phương pháp điều trị phù hợp, từ đó cải thiện tiên lượng cho bệnh nhân. Ảnh cộng hưởng từ đa phương thức (multimodal MRI), bao gồm các chuỗi xung T1, T1ce, T2 và FLAIR, cung cấp thông tin toàn diện về cấu trúc giải phẫu và đặc điểm bệnh học của khối u. Trong những năm gần đây, các phương pháp dựa trên học sâu, đặc biệt là các mạng nơ-ron tích chập như U-Net và biến thể tự cấu hình nnU-Net, đã trở thành chuẩn phổ biến cho bài toán này và được báo cáo là đạt hiệu năng phân đoạn cạnh tranh hàng đầu (state-of-the-art) trên các bộ dữ liệu chuẩn như BraTS [1, 2, 3].

Mặc dù đạt được độ chính xác ấn tượng, việc triển khai các mô hình phân đoạn này trong thực tế lâm sàng vẫn đối mặt với những thách thức đáng kể liên quan đến độ tin cậy. Phần lớn các mô hình hiện đại hoạt động như những hệ thống “hộp đen”, chỉ cung cấp kết quả phân đoạn cuối cùng mà không kèm theo thông tin về mức độ chắc chắn của dự đoán. Một vấn đề nghiêm trọng là hiện tượng tự tin thái quá (overconfidence), trong đó các lớp kích hoạt Softmax có xu hướng tạo ra các dự đoán với xác suất cao ngay cả khi mô hình đưa ra kết quả sai hoặc khi gặp dữ liệu bị nhiễu hay ngoài

phân phối (out-of-distribution – OOD) [4]. Trong bối cảnh y tế, những dự đoán sai nhưng có độ tin cậy cao như vậy có thể dẫn đến các quyết định lâm sàng rủi ro.

Nguyên nhân cốt lõi của vấn đề này nằm ở bản chất của Softmax, vốn chỉ cung cấp một ước lượng điểm (point estimate) cho phân phối nhãn và không thể biểu diễn hay phân biệt các nguồn bất định khác nhau. Trong thực tế, bất định trong phân đoạn y sinh thường bao gồm hai thành phần chính: bất định aleatoric, phát sinh từ nhiễu nội tại của dữ liệu hoặc ranh giới mờ của khối u, và bất định epistemic, phản ánh sự thiếu hiểu biết của mô hình đối với các mẫu hiếm hoặc chưa từng quan sát trong quá trình huấn luyện [5]. Việc không phân biệt được hai loại bất định này khiến các mô hình phân đoạn khó có khả năng tự đánh giá mức độ tin cậy của chính mình.

Để giải quyết những hạn chế trên, Evidential Deep Learning (EDL) đã được đề xuất như một hướng tiếp cận thay thế, trong đó đầu ra của mạng được diễn giải như các bằng chứng và được tham số hóa bằng phân phối Dirichlet dựa trên lý thuyết bằng chứng Dempster–Shafer [6]. Cách tiếp cận này cho phép ước lượng bất định trực tiếp trong một lần suy luận (single-pass inference), tránh chi phí tính toán lớn của các phương pháp Bayesian dựa trên lấy mẫu như MC Dropout hay ensemble [7]. Tuy nhiên, các nghiên cứu gần đây cho thấy việc tích hợp EDL vào các mô hình phân đoạn thường dẫn đến sự suy giảm hiệu năng phân đoạn, đặc biệt là chỉ số Dice, làm nổi bật sự đánh đổi giữa độ chính xác và khả năng ước lượng bất định [8, 9].

*Corresponding author. Giảng viên hướng dẫn

thienntb@uit.edu.vn (T.B. Nguyen-Tat)

orcid(s):

Trong nghiên cứu này, chúng tôi đề xuất một khung Evidential Deep Learning tích hợp với kiến trúc nnU-Net nhằm giải quyết trực tiếp sự đánh đổi này. Bằng cách thiết kế một hàm mất mát mới và áp dụng cơ chế phân rã bất định thành các thành phần aleatoric và epistemic, phương pháp của chúng tôi hướng tới việc duy trì và cải thiện hiệu năng phân đoạn đồng thời cung cấp thông tin bất định có khả năng diễn giải, góp phần nâng cao độ tin cậy của các hệ thống phân đoạn khối u não trong thực tế lâm sàng.

2. Các nghiên cứu liên quan

2.1. Học sâu trong phân đoạn khối u não

Trong hơn một thập kỷ qua, các mạng nơ-ron tích chập (CNN) đã tạo ra những bước tiến đáng kể trong phân tích ảnh y tế, đặc biệt là bài toán phân đoạn khối u não từ ảnh cộng hưởng từ. Kiến trúc U-Net, với cơ chế kết nối tắt (skip connections) giữa các tầng mã hóa và giải mã, đã trở thành nền tảng cho hầu hết các mô hình phân đoạn y sinh hiện đại nhờ khả năng kết hợp hiệu quả thông tin ngữ cảnh và chi tiết không gian [1]. Dựa trên U-Net, nhiều biến thể và cải tiến đã được đề xuất nhằm xử lý dữ liệu đa phương thức và cấu trúc khối u phức tạp.

Gần đây, nnU-Net được giới thiệu như một khung phân đoạn tự cấu hình, có khả năng tự động điều chỉnh kiến trúc mạng, chiến lược tiền xử lý và siêu tham số huấn luyện theo đặc điểm của từng bộ dữ liệu [2]. Nhờ cách tiếp cận chuẩn hóa toàn bộ pipeline, nnU-Net đã đạt được hiệu năng phân đoạn hàng đầu trên các bộ dữ liệu benchmark như BraTS và được xem là chuẩn tham chiếu trong cộng đồng nghiên cứu [3]. Tuy nhiên, các mô hình dựa trên nnU-Net về bản chất vẫn là các mô hình tất định (deterministic), không cung cấp thông tin về độ tin cậy của dự đoán, điều này hạn chế khả năng ứng dụng trong các kịch bản hỗ trợ quyết định lâm sàng.

2.2. Ước lượng độ bất định: Tiếp cận Bayesian và Evidential

Nhằm khắc phục hạn chế “hộp đen” của các mô hình tất định, nhiều phương pháp ước lượng bất định đã được đề xuất trong học sâu. Các phương pháp Bayesian, tiêu biểu như Monte Carlo Dropout và Deep Ensembles, xấp xỉ phân phối hậu nghiệm của mô hình bằng cách thực hiện nhiều lần suy luận ngẫu nhiên trong giai đoạn dự đoán [7, 10]. Mặc dù cho phép ước lượng bất định ở mức độ nhất định, các phương pháp này thường đòi hỏi chi phí tính toán cao do phải thực hiện nhiều forward passes, gây khó khăn cho các ứng dụng thời gian thực hoặc các bài toán phân đoạn 3D quy mô lớn.

Evidential Deep Learning (EDL) được đề xuất như một hướng tiếp cận thay thế nhằm giảm chi phí suy luận. Dựa trên lý thuyết bằng chứng Dempster-Shafer, EDL diễn giải đầu ra của mạng dưới dạng các tham

số của phân phối Dirichlet, cho phép mô hình biểu diễn mức độ bằng chứng và ước lượng bất định trực tiếp trong một lần suy luận (single-pass inference), trái ngược với các phương pháp tiếp cận dựa trên lấy mẫu, [6]. Cách tiếp cận này đã cho thấy tiềm năng trong các bài toán phân loại, tuy nhiên việc mở rộng EDL sang các bài toán phân đoạn phức tạp, đặc biệt là phân đoạn khối u não, vẫn đặt ra nhiều thách thức về tính ổn định và hiệu năng.

2.3. Evidential Deep Learning cho phân đoạn khối u não


Một số nghiên cứu gần đây đã nỗ lực tích hợp EDL vào bài toán phân đoạn khối u não. TBraTS là một trong những công trình tiên phong áp dụng EDL cho phân đoạn, sử dụng kiến trúc V-Net làm backbone và tập trung vào việc ước lượng bất định epistemic thông qua các thước đo dựa trên độ trống thông tin (vacuity) [8]. Tuy nhiên, cách tiếp cận này chưa tận dụng các kiến trúc phân đoạn chuẩn hóa như nnU-Net và không mô hình hóa rõ ràng ảnh hưởng của nhiễu dữ liệu, vốn đóng vai trò quan trọng trong các vùng biên mờ hoặc dữ liệu kém chất lượng.

Gần đây hơn, phương pháp Region-based Evidential Deep Learning đã được đề xuất nhằm cải thiện EDL cho phân đoạn bằng cách kết hợp các hàm mất mát dựa trên vùng với cơ chế regularization của Dirichlet, sử dụng nnU-Net làm backbone [9]. Mặc dù phương pháp này cho thấy những cải thiện nhất định so với các cách tiếp cận EDL trước đó, một số nghiên cứu gần đây đã quan sát thấy rằng việc tích hợp EDL vào các mô hình phân đoạn có thể dẫn đến sự suy giảm hiệu năng phân đoạn so với các mô hình thuần túy, phản ánh sự đánh đổi giữa độ chính xác và khả năng ước lượng bất định.

2.4. Phân rã độ bất định và khả năng diễn giải

Trong bối cảnh ứng dụng lâm sàng, không chỉ mức độ bất định tổng thể mà cả nguồn gốc của bất định đều mang ý nghĩa quan trọng. Trong học sâu, bất định thường được phân loại thành hai thành phần chính: bất định aleatoric, phản ánh nhiễu nội tại của dữ liệu quan sát, và bất định epistemic, liên quan đến sự thiếu hiểu biết của mô hình đối với các mẫu hiếm hoặc ngoài phân phối [5]. Việc phân rã bất định thành các thành phần này giúp cải thiện khả năng diễn giải và hỗ trợ các quyết định lâm sàng an toàn hơn.

Mặc dù khái niệm phân rã bất định đã được nghiên cứu trong các bài toán phân loại và thị giác máy tính tổng quát, phần lớn các phương pháp phân đoạn y sinh hiện nay chỉ cung cấp một bản đồ bất định tổng hợp, thường được suy ra từ entropy hoặc phương sai của dự đoán [11]. Ngay cả trong các phương pháp EDL cho phân đoạn, trọng tâm chủ yếu vẫn đặt vào việc ước lượng bất định tổng thể, trong khi việc phân rã rõ ràng các thành phần aleatoric và epistemic trong không gian phân đoạn vẫn chưa được nghiên cứu một cách hệ thống.



Hình 1: Sơ đồ tổng quan kiến trúc EDL-nnU-Net đề xuất. Mô hình nhận đầu vào là ảnh MRI đa phương thức (BraTS) và sử dụng kiến trúc Encoder-Decoder (nnU-Net) để trích xuất đặc trưng. Đầu ra không sử dụng Softmax truyền thống mà được mô hình hóa dưới dạng phân phối Dirichlet, cho phép ước lượng đồng thời bản đồ phân đoạn và các thành phần độ bất định (aleatoric và epistemic) trong một lần truyền xuôi.

Do đó, vẫn còn thiếu các phương pháp phân đoạn khối u não có khả năng vừa duy trì hiệu năng phân đoạn cao, vừa cung cấp bản đồ bất định có thể phân rõ và diễn giải rõ ràng, đặc biệt khi sử dụng các backbone chuẩn hóa như nnU-Net. Khoảng trống này chính là động lực cho phương pháp được đề xuất trong nghiên cứu này.

3. Phương pháp đề xuất

3.1. Tổng quan về framework đề xuất

Chúng tôi đề xuất một khung phân đoạn khối u não dựa trên Evidential Deep Learning, được tích hợp trực tiếp vào kiến trúc nnU-Net v2 thông qua một cơ chế huấn luyện tùy biến, nhằm đồng thời đạt được hiệu năng phân đoạn cao và khả năng định lượng bất định có khả năng diễn giải.

Khác với các phương pháp mở rộng nnU-Net bằng cách thay đổi kiến trúc hoặc pipeline tiền xử lý, phương pháp của chúng tôi giữ nguyên toàn bộ cơ chế tự cấu hình của nnU-Net, bao gồm chiến lược tiền xử lý, lập kế hoạch kiến trúc, deep supervision và chiến lược huấn luyện mặc định. Phần mở rộng được thực hiện bằng cách tiêm (inject) một trainer tùy biến vào khung huấn luyện của nnU-Net v2, cho phép thay thế lớp đầu ra và hàm mất mát mà không làm gián đoạn các thành phần đã được tối ưu hóa sẵn của hệ thống.

Tổng thể, khung phương pháp bao gồm ba thành phần chính. Thứ nhất, nnU-Net v2 đóng vai trò backbone phân đoạn 3D, xử lý dữ liệu MRI đa phương thức và tạo ra các bản đồ logits cho từng voxel. Thứ hai, các logits này được ánh xạ sang bằng chứng không âm thông qua hàm kích hoạt Softplus, từ đó tham số hóa một phân phối Dirichlet cho mỗi voxel và mỗi lớp phân đoạn. Thứ ba, một hàm mất mát tổng hợp mới được thiết kế nhằm cân bằng giữa tối ưu hóa Dice score và việc học bằng chứng một cách có kiểm soát, tránh hiện tượng suy giảm hiệu năng thường gặp trong các phương pháp EDL trước đó.

Ở giai đoạn suy luận, framework cho phép tính toán phân phối dự đoán kỳ vọng và các bản đồ bất định chỉ trong một lần truyền xuôi (single-pass inference), đồng thời hỗ trợ phân rã bất định thành các thành phần aleatoric và epistemic. Điều này giúp phương pháp phù hợp với các kịch bản lâm sàng thực tế, nơi yêu cầu cả độ chính xác, độ tin cậy và hiệu quả tính toán.

3.2. Mô hình hóa Evidential với phân phối Dirichlet

Trong các mô hình phân đoạn truyền thống, đầu ra của mạng thường được chuẩn hóa bằng hàm Softmax để tạo ra một phân phối xác suất điểm trên các lớp. Cách tiếp cận này không cho phép mô hình biểu diễn mức độ thiếu chắc chắn của chính dự đoán, đồng thời dễ dẫn đến hiện tượng tự tin thái quá khi đối mặt với dữ liệu nhiễu hoặc ngoài phân phối.

Trong khuôn khổ Evidential Deep Learning, chúng tôi diễn giải đầu ra của mạng như các bằng chứng thay vì xác suất trực tiếp, từ đó tham số hóa một phân phối Dirichlet [6]. Cụ thể, với mỗi voxel i và mỗi lớp phân đoạn $k \in \{1, \dots, K\}$, mạng dự đoán một logit z_{ik} . Logit này được chuyển đổi thành bằng chứng không âm thông qua hàm kích hoạt Softplus:

$$e_{ik} = \text{Softplus}(z_{ik}) = \ln(1 + \exp(z_{ik})) \quad (1)$$

Đây là một hàm kích hoạt trơn và không âm (smooth non-negative activation), giúp đảm bảo tính hợp lệ của bằng chứng đồng thời duy trì gradient mượt ngay cả với các logit âm, khắc phục hạn chế của ReLU trong bối cảnh học bằng chứng.

Các bằng chứng này được dùng để tham số hóa phân phối Dirichlet:

$$\alpha_{ik} = e_{ik} + 1 \quad (2)$$

trong đó $\alpha_i = \{\alpha_{i1}, \dots, \alpha_{iK}\}$ xác định một phân phối Dirichlet trên simplex xác suất cho voxel i . Khi không có bằng chứng ($e_{ik} = 0$), ta có $\alpha_{ik} = 1$, tương ứng với phân phối đồng đều và mức bất định tối đa.

Xác suất dự đoán kỳ vọng cho mỗi lớp được tính trực tiếp từ phân phối Dirichlet:

$$\hat{p}_{ik} = \mathbb{E}[p_{ik}] = \frac{\alpha_{ik}}{S_i}, \quad S_i = \sum_{k=1}^K \alpha_{ik} \quad (3)$$

Khác với xác suất Softmax, $\hat{p}_{ik}$ không chỉ phản ánh xu hướng phân lớp mà còn phụ thuộc vào tổng cường độ bằng chứng S_i . Khi S_i nhỏ, phân phối Dirichlet trở nên phẳng, phản ánh sự thiếu chắc chắn của mô hình; khi S_i lớn, phân phối trở nên tập trung hơn, biểu thị mức độ tự tin cao.

Trong nghiên cứu này, các xác suất kỳ vọng $\hat{p}_{ik}$ được sử dụng trực tiếp để tối ưu hóa hàm Dice loss, trong khi các tham số Dirichlet được khai thác để học và phân tích bất định. Cách thiết kế này cho phép mô hình duy trì hành vi phân đoạn tương tự nnU-Net chuẩn, đồng thời mở rộng đầu ra để hỗ trợ định lượng và phân rã bất định một cách có hệ thống.

3.3. Hàm mất mát tổng hợp bảo toàn độ chính xác (Accuracy-Preserving Composite Loss)

Một thách thức cốt lõi khi áp dụng Evidential Deep Learning cho bài toán phân đoạn là sự đánh đổi giữa hiệu năng phân đoạn và khả năng ước lượng bất định. Các hàm mất mát EDL truyền thống thường ưu tiên tối ưu hóa bằng chứng (evidence) nhưng thiếu sự tập trung vào độ chồng lấp hình học (geometric overlap), dẫn đến hiện tượng hội tụ chậm và chỉ số Dice thấp hơn so với các phương pháp phân đoạn nền tảng mạnh mẽ (strong segmentation baselines).

Để giải quyết vấn đề này, chúng tôi đề xuất một hàm mất mát tổng hợp mới. Hàm mất mát này tích hợp Soft Dice Loss để duy trì hiệu năng phân đoạn của nnU-Net [12], đồng thời sử dụng Bayes Risk để học bằng chứng một cách hiệu quả [6]. Tổng hàm mất mát được định nghĩa như sau:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{seg}} + \mathcal{L}_{\text{risk}} + \lambda_t \mathcal{L}_{\text{KL}} \quad (4)$$

trong đó λ_t là hệ số trọng số thay đổi theo thời gian (annealing coefficient) để kiểm soát thành phần regularization.

3.3.1. Hàm mất mát phân đoạn trên phân phối dự đoán kỳ vọng

Thành phần $\mathcal{L}_{\text{seg}}$ đóng vai trò chủ đạo trong việc đảm bảo độ chính xác phân đoạn. Thay vì tính loss trên logits, chúng tôi tính Soft Dice Loss trực tiếp trên phân phối dự đoán kỳ vọng của Dirichlet $\hat{p}_{ik} = \alpha_{ik}/S_i$:

$$\mathcal{L}_{\text{seg}} = 1 - \frac{2 \sum_i \sum_k \hat{p}_{ik} y_{ik}}{\sum_i \sum_k (\hat{p}_{ik} + y_{ik})} \quad (5)$$

Cách tiếp cận này giúp gradient từ sai số phân đoạn được lan truyền ngược trực tiếp để điều chỉnh các tham số Dirichlet α_{ik} , đảm bảo rằng mô hình không chỉ học được phân phối xác suất mà còn tối ưu hóa được hình dạng vùng tổn thương [12].

3.3.2. Rủi ro Bayes (Bayes risk) cho việc học bằng chứng

Để mô hình học được bằng chứng từ dữ liệu, chúng tôi sử dụng Bayes Risk loss, được định nghĩa là kỳ vọng của Cross-Entropy loss trên phân phối Dirichlet [6]:

$$\mathcal{L}_{\text{risk}} = \sum_i \sum_k y_{ik} (\psi(S_i) - \psi(\alpha_{ik})) \quad (6)$$

trong đó $\psi(\cdot)$ là hàm digamma. Thành phần này phạt mô hình nếu nó gán ít bằng chứng cho lớp đúng (ground truth) và nhiều bằng chứng cho các lớp sai.

3.3.3. Điều chuẩn KL divergence với chiến lược Annealing

Để ngăn chặn hiện tượng tự tin thái quá (overconfidence), chúng tôi áp dụng KL divergence để ép phân phối dự đoán về dạng phân phối Dirichlet đồng đều (Uniform Dirichlet) đối với các mẫu khó hoặc gây nhầm lẫn:

$$\mathcal{L}_{\text{KL}} = \text{KL}[\text{Dir}(\alpha_i) \parallel \text{Dir}(\mathbf{1})] \quad (7)$$

Đặc biệt, để tránh việc regularization quá mạnh làm cản trở quá trình học đặc trưng ở giai đoạn đầu, chúng tôi áp dụng cơ chế Annealing cho hệ số λ_t [6]. Cụ thể, λ_t được tăng tuyến tính từ 0 đến 1 trong các epoch huấn luyện đầu tiên (early training epochs). Điều này cho phép mô hình ưu tiên học phân đoạn chính xác trước khi dần dần học cách hiệu chỉnh độ bất định.

3.4. Phân rã độ bất định (Uncertainty Decomposition)

Một ưu điểm lớn của phương pháp đề xuất là khả năng phân rã độ bất định tổng thể thành hai thành phần có ý nghĩa lâm sàng riêng biệt: bất định aleatoric và epistemic, dựa trên các nguyên lý của lý thuyết thông tin [5, 13].

3.4.1. Độ bất định dự đoán tổng thể (Total predictive uncertainty)

Độ bất định tổng thể được đo bằng entropy của phân phối dự đoán kỳ vọng:

$$\mathcal{H}_{\text{total}} = H[\mathbb{E}_{p(\mathbf{p}|\alpha)}[\mathbf{p}]] = - \sum_k \hat{p}_{ik} \ln(\hat{p}_{ik}) \quad (8)$$

Đại lượng này đại diện cho sự không chắc chắn chung của dự đoán nhưng không phân biệt nguồn gốc lỗi.

3.4.2. Độ bất định ngẫu nhiên (Aleatoric uncertainty)

Bất định aleatoric (nhiều dữ liệu) được ước lượng bằng kỳ vọng của entropy trên phân phối Dirichlet [13]:

$$\mathcal{U}_{\text{aleatoric}} = \mathbb{E}_{p(\mathbf{p}|\alpha)}[H[\mathbf{p}]] \approx \sum_k \hat{p}_{ik} (\psi(S_i+1) - \psi(\alpha_{ik}+1)) \quad (9)$$

Giá trị này thường cao ở các vùng ranh giới khối u hoặc vùng có nhiễu ảnh (motion artifacts), phản ánh sự nhập nhằng vốn có của dữ liệu đầu vào. Để có cái nhìn trực quan về cách phân phối xác suất co cụm trên không gian Simplex khi nhiều dữ liệu tăng cao, vui lòng xem minh họa tại Phụ lục B (Hình 8).

Quan sát Hình 8 (giữa) giúp giải thích trực quan công thức trên: Khi mô hình "lường lự" giữa các lớp (ví dụ tại viền khối u), trọng số bằng chứng α sẽ khiến phân phối xác suất dồn về trọng tâm của đơn hình, dẫn đến giá trị Entropy kỳ vọng tăng cao.

3.4.3. Độ bất định nhận thức (Epistemic uncertainty)

Bất định epistemic (lỗi mô hình) được tính bằng thông tin tương hỗ (Mutual Information) giữa dự đoán và tham số mô hình:

$$\mathcal{U}_{\text{epistemic}} = \mathcal{H}_{\text{total}} - \mathcal{U}_{\text{aleatoric}} \quad (10)$$

Epistemic uncertainty đóng vai trò như một chỉ báo về hành vi ngoài phân phối (indicator of out-of-distribution behavior). Giá trị này tăng cao khi mô hình gặp các mẫu dữ liệu lạ chưa từng xuất hiện trong tập huấn luyện, giúp bác sĩ nhận biết các ca bệnh cần sự can thiệp của chuyên gia.

4. Thiết lập thực nghiệm

4.1. Dữ liệu và chi tiết cài đặt

4.1.1. Dữ liệu và Tiền xử lý

Chúng tôi đánh giá phương pháp đề xuất trên bộ dữ liệu chuẩn BraTS 2020 [3], bao gồm các ảnh cộng hưởng từ đa phương thức (T1, T1ce, T2 và FLAIR) của 369 bệnh nhân được chẩn đoán u thần kinh đệm (glioma). Mỗi mẫu dữ liệu được gán nhãn voxel-wise bởi các chuyên gia, với ba lớp chính: hoại tử và không tăng quang (NCR/NET – nhãn 1), phù nề (ED – nhãn 2), và lõi tăng quang (ET – nhãn 4).

Hiệu năng phân đoạn được đánh giá trên ba vùng lâm sàng lồng nhau (nested regions), bao gồm: Whole Tumor (WT), đại diện cho toàn bộ vùng u (nhãn $1 \cup 2 \cup 4$); Tumor Core (TC), bao gồm vùng hoại tử và lõi tăng quang (nhãn $1 \cup 4$); và Enhancing Tumor (ET), chỉ bao gồm lõi tăng quang (nhãn 4). Cách phân chia này tuân theo giao thức đánh giá tiêu chuẩn của các thử thách BraTS.

Phân chia dữ liệu. Việc phân chia dữ liệu huấn luyện và kiểm định được thực hiện tự động bởi framework nnU-Net nhằm đảm bảo tính khách quan và khả năng tái lập. Cụ thể, chúng tôi sử dụng seed ngẫu nhiên cố định mặc định là 12345, và file cấu hình phân chia (splits_final.json) được tạo ra theo chiến lược kiểm định chéo 5 lần (5-fold cross-validation). Trong phạm vi báo cáo này, các kết quả được trình bày dựa trên cấu hình phân chia của Fold 0.

Toàn bộ dữ liệu được tiền xử lý tự động theo pipeline self-configuring của nnU-Net v2 [2]. Quy trình

này bao gồm chuẩn hóa cường độ bằng z-score cho từng phương thức MRI, cắt vùng não (brain cropping), và lấy mẫu lại (resampling) về cùng độ phân giải không gian.

4.1.2. Cấu hình mạng và Huấn luyện

Các thực nghiệm được triển khai trên nền tảng PyTorch, sử dụng framework nnU-Net v2. Chúng tôi so sánh hai cấu hình mô hình:

1. Baseline: Mô hình nnU-Net chuẩn (cấu hình 3d_fullres), sử dụng hàm kích hoạt Softmax và hàm mất mát kết hợp Dice và Cross-Entropy.
2. Proposed EDL-nnU-Net: Mô hình đề xuất, trong đó lớp đầu ra được thay thế bằng hàm kích hoạt Softplus và hàm mất mát tổng hợp như mô tả ở Section 3.

Cả hai mô hình được huấn luyện trên cùng một phần cứng, cụ thể là GPU NVIDIA Tesla P100 (16GB VRAM), nhằm đảm bảo điều kiện so sánh công bằng. Theo thiết lập mặc định của nnU-Net, chúng tôi sử dụng bộ tối ưu hóa Stochastic Gradient Descent (SGD) với momentum 0.99 và hệ số weight decay 3×10^{-5} . Tốc độ học ban đầu được đặt là 0.01 và được điều chỉnh theo chính sách poly learning rate scheduler.

Để đánh giá hiệu quả hội tụ và khả năng duy trì hiệu năng phân đoạn, chúng tôi thiết lập giới hạn huấn luyện là 50 epochs cho cả hai mô hình, với thời gian huấn luyện trung bình ở mức vài phút cho mỗi epoch trên GPU được sử dụng. Đối với mô hình EDL-nnU-Net, hệ số annealing λ của thành phần KL divergence được tăng tuyến tính từ 0 đến 1 trong suốt quá trình huấn luyện. Chiến lược này cho phép mô hình ưu tiên học phân đoạn chính xác ở giai đoạn đầu, đồng thời dần dần hiệu chỉnh độ bất định mà không cần thời gian huấn luyện kéo dài hàng nghìn epoch như cấu hình mặc định của nnU-Net.

4.2. Các phương pháp đối chứng

Để đánh giá vị thế của phương pháp đề xuất trong bối cảnh nghiên cứu hiện tại, chúng tôi so sánh với ba phương pháp đối chứng đại diện cho các hướng tiếp cận khác nhau trong bài toán phân đoạn khối u não.

- Standard nnU-Net (Deterministic baseline) [2]: Đây là chuẩn tham chiếu cho phân đoạn y sinh nhờ hiệu năng ổn định và khả năng tự cấu hình trên nhiều bộ dữ liệu khác nhau. Trong nghiên cứu này, nnU-Net đóng vai trò là mốc so sánh quan trọng để đánh giá liệu việc tích hợp Evidential Deep Learning có thể duy trì hiệu năng phân đoạn của một mô hình tất định mạnh hay không. Điều này đặc biệt quan trọng vì nhiều phương pháp ước lượng bất định trước đây thường phải đánh đổi độ chính xác phân đoạn để đổi lấy khả năng biểu diễn độ bất định.
- TBraTS (Trusted Brain Tumor Segmentation) [8]: TBraTS là một trong những công trình tiên

phong tích hợp Evidential Deep Learning vào bài toán phân đoạn khối u não. Phương pháp này sử dụng kiến trúc V-Net làm backbone và định lượng độ bất định chủ yếu thông qua thước đo vacuity dựa trên Subjective Logic, phản ánh mức độ thiếu bằng chứng của mô hình. Chúng tôi lựa chọn TBraTS làm baseline nhằm so sánh với một hướng tiếp cận evidential sớm sử dụng kiến trúc backbone khác (V-Net so với U-Net).

- Region-based Evidential Deep Learning [9]: Đây là phương pháp gần nhất với nghiên cứu của chúng tôi do cùng sử dụng nnU-Net làm backbone. Phương pháp này kết hợp Evidential Deep Learning với regularization Dirichlet và sử dụng entropy của phân phối dự đoán để biểu diễn độ bất định tổng thể. Tuy nhiên, các nghiên cứu trước cho thấy việc tích hợp EDL theo hướng này thường đi kèm một mức độ đánh đổi nhất định về hiệu năng phân đoạn, do đó việc so sánh với phương pháp này cho phép đánh giá trực tiếp hiệu quả của thiết kế hàm mất mát đề xuất.

4.3. Các chỉ số đánh giá (Evaluation Metrics)

Để đánh giá toàn diện phương pháp đề xuất, chúng tôi xem xét cả độ chính xác phân đoạn (segmentation accuracy) và độ tin cậy (reliability) của các ước lượng bất định. Các chỉ số được lựa chọn tuân theo các giao thức chuẩn của cuộc thi BraTS.

4.3.1. Hiệu suất phân đoạn

Chất lượng phân đoạn được định lượng bằng Hệ số tương đồng Dice (DSC) và Khoảng cách Hausdorff 95% (HD95).

Hệ số Dice đo lường mức độ chồng lấn về thể tích giữa bản đồ phân đoạn dự đoán P và nhãn thực tế G :

$$DSC(P, G) = \frac{2|P \cap G|}{|P| + |G|} \quad (11)$$

Giá trị DSC nằm trong khoảng $[0, 1]$, càng gần 1 càng tốt.

Khoảng cách Hausdorff 95% đánh giá độ chính xác của đường biên khối u bằng cách tính phân vị thứ 95 của khoảng cách giữa các điểm trên bề mặt dự đoán và thực tế. Giá trị HD95 càng nhỏ cho thấy đường biên dự đoán càng bám sát thực tế.

4.3.2. Đánh giá độ tin cậy (Giao thức QU-BraTS)

Ngoài các chỉ số tiêu chuẩn, chúng tôi đánh giá mức độ đáng tin cậy của mô hình dựa trên giao thức từ cuộc thi QU-BraTS 2020 Challenge [14]. Khác với các thước đo hiệu chỉnh truyền thống (ví dụ như ECE, vốn chủ yếu được thiết kế cho bài toán phân loại), giao thức này đánh giá hành vi của mô hình khi các voxel có độ bất định cao bị loại bỏ dần theo một ngưỡng τ .

Chúng tôi sử dụng bản đồ độ bất định dự đoán tổng thể (total predictive uncertainty map) từ mô hình Evidential Deep Learning làm tiêu chí lọc. Quá trình

đánh giá dựa trên ba đường cong chính, biểu diễn theo tỷ lệ voxel được giữ lại (retention fraction), tức là phần trăm voxel còn lại sau khi loại bỏ các voxel có độ bất định cao hơn ngưỡng τ :

1. Dice-Retention Curve: Theo dõi sự cải thiện của chỉ số DSC khi các voxel không chắc chắn bị loại bỏ.
2. False Trust Positive (FTP): Tỷ lệ các voxel nền bị phân loại sai thành khối u nhưng với độ tin cậy cao.
3. False Trust Negative (FTN): Tỷ lệ các voxel khối u bị phân loại sai thành nền nhưng với độ tin cậy cao.

Điểm số độ tin cậy cuối cùng (QU-BraTS Score) được tính bằng trung bình cộng của Diện tích dưới đường cong (AUC) của ba thành phần trên:

$$\text{Score}_{QU} = \frac{AUC_{\text{Dice}} + (1 - AUC_{\text{FTP}}) + (1 - AUC_{\text{FTN}})}{3} \quad (12)$$

Điểm số cao cho thấy mô hình không chỉ chính xác mà còn gần độ bất định cao cho những vùng dự đoán sai.

Lưu ý về hậu xử lý (Post-processing): Cần lưu ý rằng một số chiến lược hậu định, chẳng hạn như ép buộc độ tin cậy cao cho các dự đoán (force-confidence), có thể làm tăng điểm QU-BraTS một cách giả tạo mà không thực sự cải thiện độ an toàn lâm sàng. Do đó, trừ khi có ghi chú khác, chúng tôi báo cáo kết quả dựa trên đầu ra evidential thô (raw output) để phản ánh đúng độ bất định nội tại của mô hình.

Phân tích tính bền vững (Robustness Analysis) Bên cạnh các đánh giá tiêu chuẩn, chúng tôi còn thực hiện các thí nghiệm về tính bền vững dưới tác động của nhiễu tổng hợp (synthetic noise perturbations). Mục tiêu là phân tích hành vi của các ước lượng bất định khi chất lượng hình ảnh bị suy giảm (degraded image quality). Các kết quả và phân tích chi tiết về khía cạnh này sẽ được trình bày cụ thể trong Mục 5.

5. Kết quả thực nghiệm

5.1. Hiệu năng phân đoạn (Segmentation Performance)

Để đánh giá hiệu quả của phương pháp đề xuất, chúng tôi thực hiện so sánh định lượng trên bộ dữ liệu BraTS 2020 theo hai khía cạnh: so sánh trực tiếp với baseline nội bộ (trên cùng điều kiện huấn luyện) và đối chiếu tham khảo với các kết quả SOTA đã công bố.

Do nhãn thực tế của tập Test chính thức (Official BraTS Test Set) không được công khai, chúng tôi báo cáo kết quả trên tập Validation (Fold 0) gồm 74 bệnh nhân (khoảng 20% dữ liệu), đảm bảo đây là dữ liệu chưa từng được nhìn thấy (unseen) trong quá trình huấn luyện.

Bảng 1

So sánh hiệu năng phân đoạn (Dice Score và HD95) giữa Baseline và EDL-nnU-Net trên tập Validation (Fold 0). **In đậm:** Kết quả tốt nhất.

Phương pháp	Dice Score ($\uparrow$)			HD95 (mm) ($\downarrow$)		
	WT	TC	ET	WT	TC	ET
Baseline (nnU-Net)	0.9188	0.8912	0.7969	5.6808	3.4619	3.1246
EDL-nnU-Net (Ours)	0.9259	0.8964	0.8050	5.4782	3.4807	3.2738

Bảng 2

So sánh chỉ số Dice trung bình (Average Dice) với các phương pháp khác. (*) Số liệu trích dẫn từ [9] trên tập Test nội bộ của họ.

Phương pháp	Cơ chế Loss	Avg. Dice ($\uparrow$)
EDL (TBraTS)*	Vacuity (Subjective Logic)	0.790
EDL (CE)*	Cross-Entropy + KL	0.783
Region-based EDL (wDICE)*	Region Loss + Dirichlet	0.793
Ensemble*	-	0.807
EDL-nnU-Net (Ours)	Composite Loss	0.876

5.1.1. So sánh với Baseline nội bộ (Internal Comparison)

Bảng 1 trình bày kết quả so sánh trực tiếp với mô hình nnU-Net gốc được huấn luyện lại trên cùng Fold 0.

Kết quả cho thấy phương pháp EDL-nnU-Net không những bảo toàn mà còn cải thiện nhẹ hiệu năng phân đoạn. Cụ thể, chỉ số Dice trên vùng Whole Tumor (WT) tăng từ 0.9188 lên 0.9259, và sai số biên dạng (HD95) giảm từ 5.68mm xuống 5.48mm. Điều này bác bỏ lo ngại thường gặp rằng việc tích hợp ước lượng độ bất định (vốn thêm ràng buộc KL-divergence) sẽ làm suy giảm độ chính xác phân đoạn.

5.1.2. So sánh với các phương pháp Evidential khác

Bảng 2 đối chiếu kết quả Dice trung bình (Average Dice) của chúng tôi với các phương pháp Uncertainty State-of-the-art khác được báo cáo trong tài liệu [9].

Cần lưu ý rằng việc so sánh trực tiếp này có thể chưa hoàn toàn đồng nhất do sự khác biệt trong cách phân chia tập kiểm tra nội bộ (Internal Test splits) giữa các nghiên cứu. Tuy nhiên, mô hình đề xuất đạt mức Dice trung bình 0.876, vượt trội đáng kể so với TBraTS (0.790) hay Region-based EDL (0.793). Mặc dù các phương pháp được đánh giá trên các tập kiểm tra nội bộ khác nhau, sự chênh lệch lớn này ($> 8\%$) vẫn cho thấy xu hướng rõ ràng về ưu thế của việc kết hợp backbone nnU-Net với hàm mất mát Composite Loss đề xuất.


Trong các nghiên cứu tương lai, chúng tôi sẽ tiến hành cài đặt và huấn luyện lại (re-implement) các phương pháp đối chứng này ngay trên tập Validation của chúng tôi để đảm bảo tính công bằng tuyệt đối về mặt số liệu.

5.2. Kết quả định tính (Qualitative Results)

Trong khi các kết quả định lượng ở mục trước cho thấy hiệu năng phân đoạn cạnh tranh, phân tích định tính đóng vai trò quan trọng để làm rõ cách thức mô hình biểu diễn và diễn giải độ bất định ở mức voxel. Hình 2 minh họa kết quả trên một lát cắt MRI tiêu biểu (Slice 104, Bệnh nhân BRATS_019) thuộc tập Validation.

Quan sát kết quả định tính cho thấy những đặc điểm nổi bật sau:

1. Độ chính xác về hình thái (Morphological Accuracy): Bản đồ phân đoạn dự đoán (Predicted Segmentation) bám sát cấu trúc giải phẫu của khối u so với nhãn thực tế. Mô hình phân tách rõ ràng ba vùng chức năng: lõi hoại tử, vùng phù nề bao quanh và lõi tăng quang, ngay cả khi các vùng này có hình dạng phức tạp và ranh giới không đều.
2. Khả năng giải thích thông qua Độ bất định (Interpretability via Uncertainty): Trong phân tích định tính này, chúng tôi tập trung vào hai thành phần phân rã là Aleatoric và Epistemic để làm rõ nguồn gốc của độ bất định; bản đồ độ bất định tổng thể (total uncertainty) sẽ được sử dụng chính trong đánh giá định lượng độ tin cậy ở Mục 5.3.
 - Tập trung tại vùng biên (Boundary Awareness): Cả hai bản đồ bất định đều đạt giá trị cao (màu sáng) tập trung dọc theo ranh giới giữa khối u và mô lành. Điều này phản ánh đúng thực tế lâm sàng: các đường biên này thường chịu ảnh hưởng của hiệu ứng thể tích riêng phần (partial volume effect), khiến thông tin trở nên "mờ" và khó xác định nhất.
 - Nhận diện vùng chưa được học (Model Awareness): Đáng chú ý, độ bất định nhận




Hình 2: Trực quan hóa kết quả phân đoạn và phân rã độ bất định của mô hình EDL-nnU-Net. Từ trái qua phải: (1) Ảnh MRI đầu vào; (2) Nhãn thực tế (Ground Truth); (3) Bản đồ phân đoạn dự đoán (Predicted Segmentation) với các vùng màu: Đỏ (Hoại tử/NCR), Xanh (Phù nề/ED), Vàng (Lõi tăng quang/ET); (4) Độ bất định ngẫu nhiên (Aleatoric Uncertainty); và (5) Độ bất định nhận thức (Epistemic Uncertainty). Các vùng sáng màu trong bản đồ bất định thể hiện mức độ không chắc chắn cao của mô hình.

thức (Epistemic) không lan rộng một cách ngẫu nhiên mà tập trung cục bộ tại các điểm khó. Điều này cho thấy mô hình không chỉ phản ánh nhiều dữ liệu mà còn có khả năng nhận diện các vùng đặc trưng chưa được học đầy đủ trong quá trình huấn luyện, từ đó đưa ra tín hiệu cảnh báo thay vì dự đoán sai một cách quả quyết.

5.3. Đánh giá độ tin cậy (Reliability Analysis)

Để kiểm chứng khả năng "tự nhận thức lỗi" của mô hình, chúng tôi sử dụng giao thức QU-BraTS. Trong nghiên cứu này, độ bất định tổng thể (Total Uncertainty) được tính bằng Entropy của phân phối dự đoán kỳ vọng từ Dirichlet posterior, nhất quán với các thiết lập chuẩn trong [9]. Phân tích tập trung vào lớp Enhancing Tumor (ET) – vùng tổn thương quan trọng nhất nhưng cũng thách thức nhất.

5.3.1. Phân tích đường cong hiệu năng - độ bất định



Hình 3: Đường cong Dice-Retention cho lớp Enhancing Tumor (ET).

Hình 3 biểu diễn mối quan hệ giữa hiệu năng phân đoạn (Dice Score) và ngưỡng lọc độ bất định (τ).

Quan sát đường màu đỏ (Total Unc, $AUC_{Dice} = 0.859$) cho thấy một xu hướng tăng trưởng rõ rệt: chỉ số Dice tăng từ ~ 0.81 lên đến gần 1.0. Điều này chứng minh cơ chế Fail-safe: mô hình gán độ bất định rất cao cho những vùng nó dự đoán sai. Đặc biệt, đường

Bảng 3

So sánh điểm số tin cậy (QU-Score/BraS) với các phương pháp khác. (*) Giá trị trích dẫn từ [9] trên tập Test nội bộ. (**) Giá trị của chúng tôi là trung bình cộng QU-Score của 3 vùng trên tập Validation.

Phương pháp	Dataset	Score ($\uparrow$)
EDL (TBraTS)*	Test (Internal)	0.862
Region-based EDL (Best)*	Test (Internal)	0.876
EDL-nnU-Net (Ours)**	Val (Fold 0)	0.905


Aleatoric (nét chấm xanh lá) bám sát đường Total hơn so với Epistemic, gợi ý rằng phần lớn sự không chắc chắn ở vùng ET đến từ nhiều dữ liệu (biên mờ) hơn là do thiếu dữ liệu huấn luyện.

5.3.2. Điểm số QU-BraTS và So sánh với SOTA

Bảng 3 so sánh điểm số tin cậy (BraS/QU-Score) của chúng tôi với các phương pháp SOTA khác.

Mức chênh lệch điểm số đáng kể so với TBraTS (+0.043) và Region-based EDL (+0.029) là một tín hiệu tích cực. Do sự khác biệt về tập dữ liệu đánh giá, các kết quả này nên được diễn giải như một so sánh xu hướng (trend comparison) cho thấy độ tin cậy được cải thiện nhất quán, thay vì một so sánh tuyệt đối về mặt điểm số.

Lưu ý về chiến lược "Force-confidence": Chúng tôi nhận thấy việc áp dụng hậu xử lý cưỡng ép độ tự tin (force-confidence) có thể đẩy điểm số lên rất cao (ví dụ: WT đạt 0.960). Tuy nhiên, chúng tôi quyết định không sử dụng các kỹ thuật này. Chúng tôi ưu tiên sự an toàn lâm sàng (Clinical Safety) và chấp nhận điểm số thấp hơn, thay vì tạo ra "False Trust" (tin cậy giả) - tình trạng nguy hiểm khi AI dự đoán sai nhưng lại khẳng định chắc chắn là đúng.



Hình 4: Phân tích tác động của độ mờ (Gaussian Blur) đối với độ bất định trên bệnh nhân BRATS_019 (Slice 104). **Hàng dọc:** Mức độ làm mờ tăng dần (Level 0.0 đến 1.5). **Các cột:** (1) Ảnh đầu vào; (2) Nhãn thực tế; (3) Dự đoán; (4) Total Uncertainty; (5) Aleatoric; (6) Epistemic. Có thể thấy khi ảnh mờ đi, chỉ số Dice giảm mạnh (WT: 0.90 → 0.83), đồng thời bản đồ Aleatoric sáng rực lên tại các đường biên.

5.4. Phân tích tính bền vững (Robustness Analysis)

Trong môi trường lâm sàng thực tế, chất lượng ảnh MRI có thể bị suy giảm do chuyển động của bệnh nhân hoặc hạn chế của thiết bị (máy MRI từ trường thấp). Để đánh giá tính bền vững của mô hình, chúng tôi thực hiện các thử nghiệm định tính bằng cách tác động các loại nhiễu nhân tạo lên dữ liệu đầu vào.

Chúng tôi tập trung phân tích sâu vào tác động của Gaussian Blur (làm mờ), vì đây là tác nhân gây ảnh hưởng nghiêm trọng nhất đến khả năng xác định đường biên khối u (xem Hình 4).

5.4.1. Phản ứng của Độ bất định dữ liệu (Aleatoric Uncertainty)

Hình 4 minh họa phản ứng của mô hình khi độ mờ của ảnh tăng dần.

- Hiện tượng khi các chi tiết cạnh (edge details) bị làm mờ, bản đồ Aleatoric Uncertainty (cột thứ 5) lập tức phản ứng bằng cách tăng độ sáng mạnh mẽ, đặc biệt tập trung tại vùng ranh giới (boundaries) giữa khối u và mô lành.
- Tác động lên hiệu năng: Chỉ số Dice Score giảm đáng kể (từ 0.90 xuống 0.83 cho vùng WT) khi mức độ mờ tăng lên Level 1.5. Điều này là hợp


lý vì thông tin cần thiết để phân định biên đã bị mất.

- Ý nghĩa: Mô hình thể hiện khả năng "tự nhận thức" rất tốt. Thay vì cố gắng đưa ra một đường biên sắc nét một cách tự tin (over-confident) trên dữ liệu mờ, mô hình mở rộng vùng bất định, phát đi tín hiệu: "Tôi phát hiện khối u tại đây, nhưng do ảnh quá mờ, tôi không chắc chắn ranh giới chính xác nằm ở đâu".

Các phân tích bổ sung với các loại nhiễu khác như Gaussian Noise (nhiều hạt) và Motion Ghosting (bóng ma do chuyển động) cho thấy Aleatoric Uncertainty cũng hoạt động hiệu quả như một bộ lọc kiểm soát chất lượng (Quality Control), phát hiện được nhiễu trên toàn cục hoặc các vết bóng mờ (chi tiết xem tại Phụ lục A).

5.4.2. Phản ứng của Độ bất định mô hình (Epistemic Uncertainty)

Để khảo sát phản ứng của độ bất định mô hình trong các tình huống ngoài phân phối huấn luyện (Out-of-Distribution – OOD), chúng tôi tiến hành chèn các dị vật nhân tạo (artificial artifacts) có hình dạng và cường độ khác nhau vào ảnh MRI đầu vào, như minh họa trong Hình 5. Về mặt trực giác, các vùng dị vật



Hình 5: Phân tích OOD với dị vật nhân tạo trên bệnh nhân BRATS_012 (Slice 119). **Các hàng:** Các loại dị vật nhân tạo khác nhau (hình vuông xám, hình vuông trắng, hình cầu trắng). **Các cột:** (1) Ảnh đầu vào có dị vật; (2) Nhãn thực tế; (3) Dự đoán của mô hình; (4) Total Uncertainty; (5) Aleatoric Uncertainty; (6) Epistemic Uncertainty. Có thể quan sát thấy vùng bên trong dị vật hầu như không kích hoạt Epistemic Uncertainty và được mô hình phân loại nhất quán là nền (background), dẫn đến entropy thấp và bản đồ bất định tối.

này được kỳ vọng sẽ kích hoạt Epistemic Uncertainty, do chúng không tương ứng với bất kỳ cấu trúc giải phẫu hoặc bệnh lý nào đã xuất hiện trong dữ liệu huấn luyện.

Tuy nhiên, kết quả thực nghiệm cho thấy bản đồ Epistemic Uncertainty chỉ thể hiện mức độ phản ứng rất hạn chế, thậm chí gần như bằng không tại vùng bên trong dị vật. Hiện tượng này có thể được giải thích một cách nhất quán dưới góc nhìn của lý thuyết thông tin và cách phân rã độ bất định trong khuôn khổ Evidential Deep Learning.

Trong mô hình EDL, Epistemic Uncertainty được định nghĩa là phần dư của tổng entropy sau khi loại bỏ thành phần aleatoric:

$$\mathcal{U}_{\text{epistemic}} = \mathcal{H}_{\text{total}} - \mathcal{U}_{\text{aleatoric}} \quad (13)$$

với $\mathcal{H}_{\text{total}}$ là entropy của phân phối xác suất kỳ vọng, và $\mathcal{U}_{\text{aleatoric}}$ là kỳ vọng entropy trên phân phối Dirichlet. Do đó, Epistemic Uncertainty không phải là một đại lượng được ước lượng trực tiếp, mà mang bản chất là một thành phần phụ thuộc vào cách phân phối entropy giữa hai nguồn bất định.

Trong các thí nghiệm với dị vật nhân tạo, mô hình có xu hướng phân loại các voxel thuộc vùng dị vật một cách nhất quán vào lớp nền (background) với xác suất rất cao. Khi xác suất dự đoán tập trung mạnh vào một lớp duy nhất, entropy tổng thể giảm mạnh, đồng thời phân phối Dirichlet trở nên sắc nét (high evidence). Trong bối cảnh này, cả Total Uncertainty và Aleatoric Uncertainty đều duy trì giá trị thấp, kéo theo Epistemic

Uncertainty, cái mà vốn được tính bằng hiệu số cũng bị suy giảm đáng kể.

Quan sát này cho thấy Epistemic Uncertainty trong khuôn khổ EDL mang tính chất bảo thủ: nó chỉ tăng lên khi mô hình thực sự thiếu bằng chứng để đưa ra một quyết định nhất quán giữa các lớp đã học. Trong trường hợp dị vật có hình dạng đơn giản, cường độ đồng nhất và không gây nhầm lẫn với mô hình bệnh lý, mô hình không rơi vào trạng thái “không biết”, mà ngược lại thể hiện sự tự tin cao trong việc loại trừ chúng khỏi vùng khối u.

Mặt khác, kết quả này cũng chỉ ra một hạn chế quan trọng của cách phân rã độ bất định dựa trên entropy. Do Aleatoric Uncertainty thường chiếm tỷ trọng lớn trong tổng entropy, đặc biệt tại các vùng ranh giới hoặc nhiễu dữ liệu, thành phần Epistemic thường có biên độ nhỏ và khó quan sát trực quan. Điều này làm giảm khả năng diễn giải Epistemic Uncertainty như một chỉ báo độc lập cho các tình huống OOD trong các kịch bản thực nghiệm đơn giản.

Tổng hợp lại, trong thiết lập hiện tại, Epistemic Uncertainty vẫn phù hợp với diễn giải lý thuyết thông tin, nhưng chưa mang lại nhiều ý nghĩa thực tiễn trong việc phát hiện các dị vật nhân tạo. Điều này gợi ý rằng để khai thác hiệu quả hơn bất định mô hình, cần xem xét các kịch bản OOD phức tạp hơn (ví dụ: dị vật có kết cấu giống mô u hoặc cường độ không đồng nhất).

6. Hạn chế và Hướng phát triển

Mặc dù các kết quả thực nghiệm cho thấy phương pháp Evidential Deep Learning (EDL) mang lại khả năng phân rã độ bất định có ý nghĩa và nhất quán với lý thuyết thông tin, nghiên cứu này vẫn tồn tại một số hạn chế cần được xem xét kỹ lưỡng, đồng thời mở ra các hướng phát triển tiềm năng trong tương lai.

6.1. Hạn chế

(1) Chưa kiểm thử trên dữ liệu lâm sàng thực tế. Toàn bộ các thí nghiệm trong nghiên cứu này được thực hiện trên tập dữ liệu BraTS 2020, vốn là một bộ dữ liệu đã được chuẩn hóa cao, bao gồm các bước tiền xử lý nghiêm ngặt và được thu thập từ nhiều trung tâm theo các giao thức tương đối đồng nhất. Do đó, mô hình chưa được đánh giá trên dữ liệu lâm sàng thực tế (real-world clinical data), nơi chất lượng ảnh MRI thường không đồng đều, chịu ảnh hưởng bởi sự khác biệt về thiết bị, giao thức chụp, cũng như đặc điểm dân số bệnh nhân. Hạn chế này làm giảm khả năng kết luận về tính tổng quát (generalizability) của cả kết quả phân đoạn và bản đồ độ bất định trong bối cảnh triển khai thực tế.

(2) Biên độ Epistemic Uncertainty còn hạn chế do bản chất của phân rã dựa trên entropy. Trong khuôn khổ EDL, Epistemic Uncertainty được định nghĩa là phần dư giữa tổng entropy và Aleatoric Uncertainty. Do Aleatoric Uncertainty thường chiếm tỷ trọng lớn trong tổng entropy, đặc biệt trong các bài toán segmentation với dữ liệu nhiễu và ranh giới mơ hồ, thành phần Epistemic thường có giá trị nhỏ và khó quan sát trực quan. Đây là một hạn chế mang tính bản chất của phương pháp phân rã dựa trên lý thuyết thông tin, thay vì là vấn đề của quá trình huấn luyện hay thiết kế mô hình.

(3) Thiết kế dị vật nhân tạo còn đơn giản. Các thí nghiệm OOD hiện tại sử dụng các dị vật nhân tạo có hình dạng và cường độ đơn giản, dẫn đến việc mô hình có thể dễ dàng phân loại chúng là nền (background) với độ tin cậy cao. Điều này làm hạn chế khả năng kích hoạt Epistemic Uncertainty và chưa phản ánh đầy đủ các dạng OOD phức tạp có thể xuất hiện trong thực tế lâm sàng.

6.2. Hướng phát triển

(1) Mở rộng đánh giá trên dữ liệu lâm sàng thực tế. Một hướng phát triển quan trọng là kiểm thử mô hình trên các tập dữ liệu MRI lâm sàng thu thập trực tiếp từ bệnh viện, với mức độ nhiễu và đa dạng cao hơn. Điều này cho phép đánh giá thực chất vai trò của Aleatoric Uncertainty như một cơ chế kiểm soát chất lượng ảnh, cũng như hành vi của Epistemic Uncertainty dưới các điều kiện domain shift thực sự.

(2) Kết hợp EDL với các phương pháp Bayesian dựa trên ensemble. Mặc dù các phương pháp như MC Dropout chỉ cung cấp bất định mang tính thống kê và không cho phép phân rã nguồn gốc bất định một cách tường minh, các phương pháp ensemble có

thể được sử dụng như một chuẩn tham chiếu cho Epistemic Uncertainty. Việc kết hợp hoặc so sánh EDL với ensemble, dù có chi phí tính toán cao hơn, có thể giúp làm rõ mối quan hệ và sự bổ sung giữa hai cách tiếp cận trong bối cảnh dữ liệu y sinh.

(3) Thiết kế các kịch bản OOD phức tạp hơn. Các nghiên cứu tiếp theo có thể tập trung vào việc xây dựng các kịch bản OOD mang tính sinh học hơn, chẳng hạn như dị vật có kết cấu giống mô u, cường độ không đồng nhất hoặc các biến dạng cấu trúc phức tạp. Những kịch bản này được kỳ vọng sẽ kích hoạt Epistemic Uncertainty rõ ràng hơn và cung cấp cái nhìn sâu sắc hơn về giới hạn hiểu biết của mô hình.

(4) Chuẩn hóa và định lượng riêng thành phần Epistemic Uncertainty. Cuối cùng, việc nghiên cứu các chiến lược chuẩn hóa hoặc tái tỉ lệ (rescaling) riêng cho Epistemic Uncertainty, cũng như xây dựng các chỉ số định lượng dành riêng cho phát hiện OOD, có thể giúp nâng cao khả năng diễn giải và ứng dụng thực tiễn của thành phần bất định này trong các hệ thống hỗ trợ quyết định lâm sàng.

A. Phân tích bổ sung về tính bền vững

Bên cạnh Gaussian Blur, chúng tôi cũng đánh giá mô hình trên hai loại nhiễu phổ biến khác là nhiễu hạt (Hình 6) và nhiễu bóng ma (Hình 7):


B. Minh họa hình học của Độ bất định

Hình 8 minh họa sự khác biệt căn bản giữa hai loại bất định dưới góc nhìn hình học trên đơn hình (Simplex) trong bài toán phân loại đa lớp.


Tài liệu

- [1] O. Ronneberger, P. Fischer, T. Brox, U-net: Convolutional networks for biomedical image segmentation, Medical Image Computing and Computer-Assisted Intervention (MICCAI) (2015).
- [2] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, K. H. Maier-Hein, nnu-net: A self-configuring method for deep learning-based biomedical image segmentation, Nature Methods (2021).
- [3] S. Bakas, M. Reyes, A. Jakab, S. Bauer, M. Rempfler, A. Crimi, R. T. Shinohara, C. Berger, S. M. Ha, G. Erus, et al., Identifying the best machine learning algorithms for brain tumor segmentation, progression assessment, and overall survival prediction in the brats challenge, arXiv preprint arXiv:1811.02629 (2018).
- [4] C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, On calibration of modern neural networks, in: International Conference on Machine Learning (ICML), 2017, pp. 1321–1330.
- [5] A. Kendall, Y. Gal, What uncertainties do we need in bayesian deep learning for computer vision?, Advances in Neural Information Processing Systems (NeurIPS) (2017).
- [6] M. Sensoy, L. Kaplan, M. Kandemir, Evidential deep learning to quantify classification uncertainty, Advances in Neural Information Processing Systems (NeurIPS) (2018).
- [7] Y. Gal, Z. Ghahramani, Dropout as a bayesian approximation: Representing model uncertainty in deep learning, International Conference on Machine Learning (ICML) (2016).

- [8] K. Zou, X. Chen, Y. Yuan, X. Shen, M. Wang, H. Fu, Tbrats: Trusted brain tumor segmentation, International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI) (2022).
- [9] J. D. S. G. Y. Hao Li, Yang Nan, Region-based evidential deep learning to quantify uncertainty and improve robustness of brain tumor segmentation, Neural Computing and Applications (2022).
- [10] B. Lakshminarayanan, A. Pritzel, C. Blundell, Simple and scalable predictive uncertainty estimation using deep ensembles, in: Advances in Neural Information Processing Systems (NeurIPS), volume 30, 2017.
- [11] T. Nair, D. Precup, D. L. Arnold, T. Arbel, Exploring uncertainty measures in deep networks for multiple sclerosis lesion detection and segmentation, Medical Image Analysis 59 (2020) 101557.
- [12] F. Milletari, N. Navab, S.-A. Ahmadi, V-net: Fully convolutional neural networks for volumetric medical image segmentation, in: International Conference on 3D Vision (3DV), 2016, pp. 565–571.
- [13] A. Malinin, M. Gales, Predictive uncertainty estimation via prior networks, in: Advances in Neural Information Processing Systems (NeurIPS), volume 31, 2018.
- [14] R. Mehta, A. Filos, U. Baid, et al., Quantifying uncertainty in brain tumor segmentation: The qu-brats 2020 challenge, in: International MICCAI Brainlesion Workshop, Springer, 2020, pp. 3–14.



Hình 6: Phản ứng với Nhiễu hạt (Gaussian Noise). Bản đồ Aleatoric tăng sáng dạng "đốm" rải rác trên toàn bộ nhu mô não, phản ánh độ tin cậy của dữ liệu giảm sút trên toàn cục (thường gặp ở máy MRI SNR thấp).



Hình 7: Phản ứng với hiện tượng Bóng ma (Motion Ghosting). Bản đồ Aleatoric bắt trọn các vết bóng lặp lại theo chiều pha, gợi ý tiềm năng ứng dụng như một công cụ cảnh báo kỹ thuật viên chụp lại cho bệnh nhân.



Hình 8: Minh họa phân phối Dirichlet trên Simplex. (Trái) Dự đoán tự tin: Phân phối tập trung tại đỉnh. (Giữa) **High Aleatoric:** Dữ liệu bị nhiễu (như vùng biên mờ) khiến các bằng chứng mâu thuẫn nhau, làm phân phối co cụm vào trung tâm (nơi Entropy đạt cực đại). (Phải) **High Epistemic:** Dữ liệu lạ (OOD) thiếu bằng chứng hỗ trợ, khiến phân phối trải phẳng đều ra các góc.